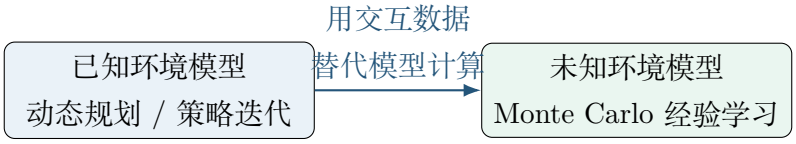
第 5 章：Monte Carlo Methods

初学者快速认识与理解指南



核心结论

本章只需要抓住一句话：**动作价值是“回报的期望”，而期望可以用多次采样回报的平均值来估计**。因此，即使不知道状态转移概率和奖励分布，也能通过与环境交互来评价策略，并逐步改进策略。

基于所给 Chapter 5（原书第 77–99 页）整理

目标：约 30–45 分钟建立完整知识框架

目录

1 先回答：这一章到底解决什么问题？ 2

1.1 学习本章前应认识的六个词 2

2 Monte Carlo 的数学起点：用样本均值估计期望 2

2.1 为什么样本均值可信？ 3

3 从均值估计到动作价值估计 3

3.1 为什么无模型控制更关心 $q_\pi(s,a)$？ 4

4 MC Basic：最容易理解的无模型策略迭代 4

5 一个数值例子：如何用回报选择动作 5

6 如何提高样本利用率：initial、first 与 every visit 6

7 MC Exploring Starts：更高效，但有一个强假设 6

7.1 Exploring Starts 是什么？ 6

8 ε-greedy：在执行过程中兼顾探索与利用 7

8.1 什么是软策略？ 7

8.2 为什么它能去掉 Exploring Starts？ 7

8.3 它能得到真正的最优策略吗？ 7

9 探索与利用：强化学习最重要的权衡之一 7

10 episode 长度与稀疏奖励为什么重要？ 8

10.1 稀疏奖励 8

11 三个算法放在一起比较 8

12 Monte Carlo 与动态规划、TD 方法的区别 9

13 初学者最容易产生的五个误解 9

14 建议的快速学习顺序 10

15 自测题与参考答案 10

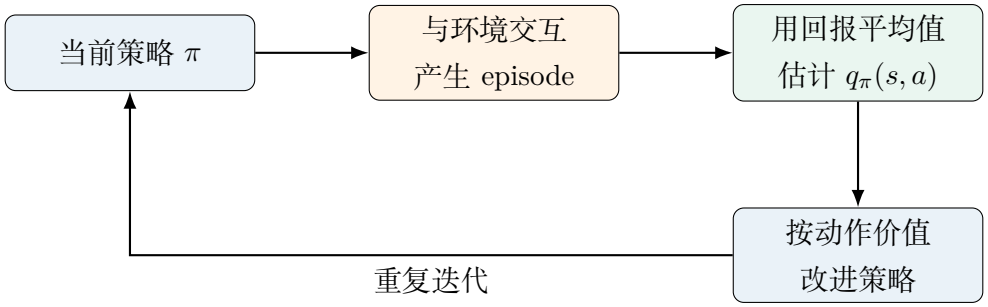
16 一页总结 11

1 先回答：这一章到底解决什么问题？

前面章节中的价值迭代和策略迭代依赖环境模型，例如状态转移概率

$$p(s' \mid s, a)$$

以及奖励分布。现实中的机器人、游戏或控制系统往往很难准确获得这些概率模型。本章开始讨论**无模型强化学习（model-free reinforcement learning）**：不显式知道模型，而是使用智能体与环境交互产生的经验数据学习策略。



核心结论

本章不是重新发明策略迭代，而是把策略迭代中的“基于模型计算价值”替换成“基于样本估计价值”。

1.1 学习本章前应认识的六个词

术语	初学者理解
状态 S_t	时刻 t 对环境情况的描述，例如机器人当前位置、关节角或棋盘位置。
动作 A_t	智能体在状态下做出的选择。
奖励 R_{t+1}	执行动作后立即获得的标量反馈。
策略 $\pi(a \mid s)$	在状态 s 下选择动作 a 的概率规则。
episode	从起点到终止（或人为截断）的一整段交互轨迹。
回报 G_t	从时刻 t 开始的未来折扣奖励总和。

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots, \qquad 0 \le \gamma < 1.$$

其中，γ 是折扣因子。γ 越大，越重视长期奖励；γ 越小，越重视近期奖励。

2 Monte Carlo 的数学起点：用样本均值估计期望

设随机变量 X 的概率分布已知，则可以直接计算

$$\mathbb{E}[X] = \sum_x p(x)x.$$

这属于**基于模型**的方法。若概率分布未知，但获得了样本 $x_1, \ldots, x_n$，则可使用样本均值

$$\bar{x}_n = \frac{1}{n} \sum_{i=1}^{n} x_i$$

近似期望：

$$\mathbb{E}[X] \approx \bar{x}_n.$$

直观理解

Monte Carlo 方法并不要求先写出概率分布。它的做法是：重复做实验、记录结果、求平均。样本越多，随机波动通常越小，平均值越接近真实期望。

2.1 为什么样本均值可信？

在独立同分布（i.i.d.）条件下，

$$\mathbb{E}[\bar{x}_n] = \mathbb{E}[X], \qquad \mathrm{Var}(\bar{x}_n) = \frac{1}{n} \mathrm{Var}(X).$$

第一式表示样本均值是无偏估计；第二式表示样本数量扩大为原来的 k 倍时，估计方差缩小为原来的 $1/k$。

抛硬币

令正面为 $X = 1$，反面为 $X = -1$，且两者概率均为 0.5。真实期望为

$$\mathbb{E}[X] = 0.5 \times 1 + 0.5 \times (-1) = 0.$$

不知道概率时，可以反复抛硬币并计算平均值。少量样本时平均值可能偏离 0；样本逐渐增加后，平均值趋近于 0。

容易混淆

原章用 i.i.d. 样本说明大数定律。强化学习轨迹中的样本常存在时间相关性，尤其是 every-visit 方法产生的多个回报可能互相重叠。相关性通常会降低“有效样本量”并增加分析难度，但并不等于 Monte Carlo 方法必然失效。

3 从均值估计到动作价值估计

动作价值函数定义为

$$q_\pi(s, a) = \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a].$$

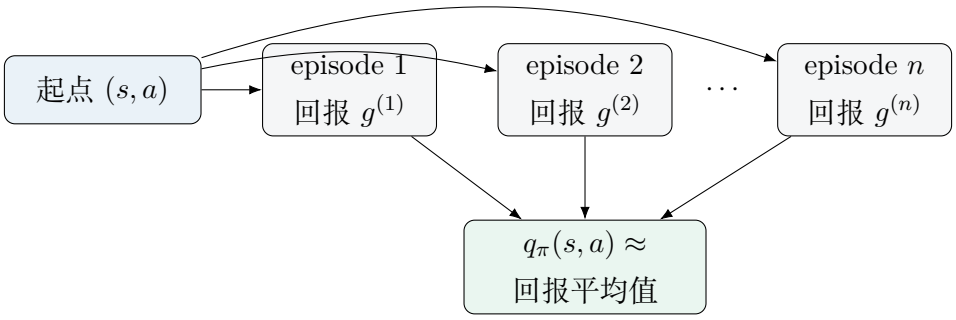
它表示：在状态 s 先执行动作 a，之后按照策略 π 行动时，能够获得的期望回报。

该公式中的关键词是**期望**。因此，可以从 (s, a) 出发，按照策略 π 生成多条 episode，得到回报

$$g_\pi^{(1)}(s, a), \ldots, g_\pi^{(n)}(s, a),$$

再用平均值估计

$$q_\pi(s,a) \approx \frac{1}{n}\sum_{i=1}^{n} g_\pi^{(i)}(s,a).$$



核心结论

Monte Carlo 强化学习的核心不是“随机搜索”，而是**利用完整轨迹的实际回报，直接估计状态价值或动作价值的期望**。

3.1 为什么无模型控制更关心 $q_\pi(s,a)$？

如果只估计状态价值 $v_\pi(s)$，为了比较不同动作，仍可能需要状态转移模型把 v_π 转换为 q_π。直接估计 $q_\pi(s,a)$ 后，可以直接选择

$$a^*(s) = \arg\max_a q_\pi(s,a),$$

从而完成策略改进，不再依赖模型。

4 MC Basic：最容易理解的无模型策略迭代

MC Basic 可以看成策略迭代的直接改造版。

策略迭代：基于模型精确或近似计算价值，再采用贪心策略改进。
MC Basic：通过多条实际 episode 的回报平均值估计动作价值，再采用贪心策略改进。

第 k 次迭代可分为两步。

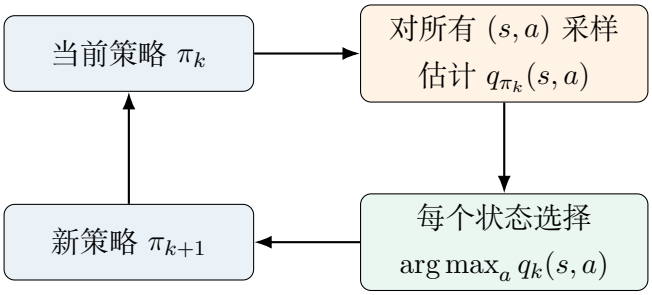
步骤 1：策略评价。 对每个状态动作对 (s,a)，从该处出发并按照当前策略 π_k 生成足够多的 episode，计算回报均值：

$$q_k(s,a) \approx q_{\pi_k}(s,a).$$

步骤 2：策略改进。 对每个状态选择当前估计价值最大的动作：

$$a_k^*(s) = \arg\max_a q_k(s,a),$$

并令新策略在该状态下确定性地选择 $a_k^*(s)$。



容易混淆

MC Basic 的思想正确，但样本效率很低：一条 episode 只被用于评价其初始状态动作对，而且需要为许多 (s,a) 分别收集大量 episode。因此它更适合作为理解原理的过渡算法，而不是实际首选算法。

5 一个数值例子：如何用回报选择动作

假设状态 s 下有两个动作，折扣因子 $\gamma = 0.9$。

- 动作 a_1 的三条 episode 回报分别为 $2.0, 1.2, 2.8$；
- 动作 a_2 的三条 episode 回报分别为 $3.1, -0.5, 1.0$。

则 Monte Carlo 估计为

$$\hat{q}(s,a_1) = \frac{2.0 + 1.2 + 2.8}{3} = 2.0,$$

$$\hat{q}(s,a_2) = \frac{3.1 - 0.5 + 1.0}{3} = 1.2.$$

因此当前贪心策略选择 a_1。

直观理解

单条轨迹中，a_2 曾得到更高回报 3.1，但动作价值比较的是**平均长期表现**，不是最好的一次表现。Monte Carlo 方法通过多次采样减少偶然性。

再看一条长度为 4 的 episode：

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, R_3, S_3, A_3, R_4.$$

从后向前计算回报最方便：

$$\begin{aligned} G_3 &= R_4, \\ G_2 &= R_3 + \gamma G_3, \\ G_1 &= R_2 + \gamma G_2, \\ G_0 &= R_1 + \gamma G_1. \end{aligned}$$

这也是后续算法伪代码通常从 episode 末端向前遍历的原因。

6 如何提高样本利用率：initial、first 与 every visit

一条 episode 往往访问多个状态动作对，例如

$$(s_1, a_2) \to (s_2, a_4) \to (s_1, a_2) \to (s_2, a_3) \to (s_5, a_1).$$

同一条轨迹可以有不同的使用方式。

策略	做法	特点
Initial-visit	只评价 episode 最开始的状态动作对。	最容易理解，但浪费后续访问。
First-visit	每个状态动作对在本 episode 第一次出现时使用一次。	避免同一 episode 内重复计数。
Every-visit	每次访问状态动作对都使用。	样本利用率最高，但同一 episode 中的回报相关性更强。

同一条 episode 能产生多少学习信息？

若轨迹中访问了 5 个时刻，Initial-visit 只更新 1 个状态动作对；First-visit 会更新每个不同状态动作对一次；Every-visit 会执行 5 次更新。后两者把每个访问之后的剩余轨迹视为一个子 episode。

7 MC Exploring Starts：更高效，但有一个强假设

MC Exploring Starts 在 MC Basic 的基础上作出两项改进：

1. 使用 first-visit 或 every-visit，更充分地利用一条 episode；
2. 每产生一条 episode 就立即更新价值与策略，不必等所有样本收集完毕。

对每个访问到的 (S_t, A_t)，累计回报并计算平均值：

$$\text{Returns}(S_t, A_t) \leftarrow \text{Returns}(S_t, A_t) + G_t,$$

$$N(S_t, A_t) \leftarrow N(S_t, A_t) + 1, \qquad q(S_t, A_t) = \frac{\text{Returns}(S_t, A_t)}{N(S_t, A_t)}.$$

7.1 Exploring Starts 是什么？

它要求 episode 的初始状态动作对具有充分的随机性，使每个 (s, a) 都有机会被选为起点，并最终被充分访问。

容易混淆

这是一个较强的理论条件。在真实机器人系统中，不能随意把机器人瞬间放到任意状态，更不能让某些危险动作作为起始动作。因此 Exploring Starts 往往难以直接满足。

这就引出下一步：不再依靠随机起点，而是在策略执行过程中持续保留探索概率。

8 ε-greedy：在执行过程中兼顾探索与利用

8.1 什么是软策略？

若一个策略在任意状态下对每个动作都赋予正概率，则称为软策略。ε-greedy 是最常见的软策略之一。

设动作数为 $|\mathcal{A}(s)|$，当前贪心动作为

$$a^* = \arg\max_a q(s, a).$$

则 ε-greedy 策略为

$$\pi(a \mid s) = \begin{cases} 1 - \varepsilon + \dfrac{\varepsilon}{|\mathcal{A}(s)|}, & a = a^*, \\ \dfrac{\varepsilon}{|\mathcal{A}(s)|}, & a \neq a^*. \end{cases}$$

$\varepsilon = 0.2$，4 个动作

贪心动作的概率为

$$1 - 0.2 + \frac{0.2}{4} = 0.85,$$

其余每个动作的概率为

$$\frac{0.2}{4} = 0.05.$$

所以算法大多数时候选择当前最优动作，但仍保留尝试其他动作的机会。

8.2 为什么它能去掉 Exploring Starts？

因为探索不再只发生在 episode 起点。只要 episode 足够长，每到达一个状态时都有非零概率选择不同动作，于是不同状态动作对能够在轨迹中逐渐被访问。

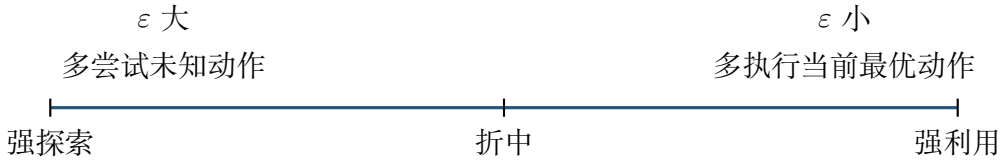
核心结论

MC ε-Greedy 与 MC Exploring Starts 的主要区别，不在于价值估计公式，而在于策略改进方式：前者把确定性贪心策略改成了保留探索概率的 ε-greedy 策略。

8.3 它能得到真正的最优策略吗？

固定 $\varepsilon > 0$ 时，算法寻找的是给定 ε 下最优的 ε-greedy 策略。它仍会故意执行非贪心动作，因此通常不等于所有策略集合中的完全贪心最优策略。ε 越小，两者通常越接近。

9 探索与利用：强化学习最重要的权衡之一



- **探索（exploration）**：尝试尚未充分评价的动作，避免错过真正的最优动作；
- **利用（exploitation）**：执行当前估计价值最大的动作，获得较高回报。

如果 ε 过大，智能体经常执行较差动作，最终性能下降；如果 ε 过小，早期价值估计存在误差时，算法可能过早固定在次优动作上。

常见实践是采用逐渐衰减的探索率，例如

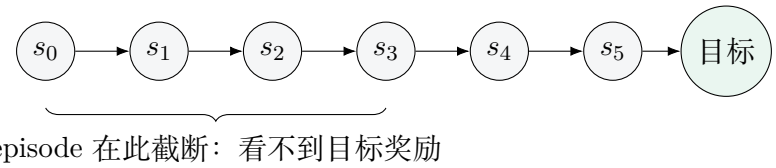
$$\varepsilon_k = \max\left(\varepsilon_{\min}, \frac{\varepsilon_0}{1+ck}\right),$$

使训练初期探索较强，后期逐渐强调利用。该式是常见工程做法，用于理解“先探索、后利用”的思想；具体衰减方式需要结合任务调整。

10 episode 长度与稀疏奖励为什么重要？

Monte Carlo 依赖完整回报。如果 episode 太短，远期奖励无法传播回较早的状态动作对。

假设从某状态到目标至少需要 15 步，而每条 episode 只保留 10 步，则该状态出发的轨迹根本看不到目标奖励。它的估计回报可能长期为 0，算法难以识别朝目标移动的动作。



10.1 稀疏奖励

稀疏奖励指大部分时间奖励为 0，只有达到目标时才获得明显正奖励。它会带来两个问题：

1. 随机策略很难偶然到达目标，因此几乎没有有效学习信号；
2. 需要更长 episode 才能把目标奖励包含进较早时刻的回报。

可通过合理的奖励塑形、课程学习或更强探索方法缓解，但奖励塑形必须避免改变原任务真正希望优化的目标。

11 三个算法放在一起比较

算法	价值估计	样本使用	探索机制	主要定位
MC Basic	多条 episode 回报取平均	主要使用初始访问，效率低	要求从各 (s,a) 收集 episode	最容易理解核心思想
MC Exploring Starts	累计访问后的回报平均	first-visit 或 every-visit	随机化 episode 起点	提高样本效率，但起点条件较强

算法	价值估计	样本使用	探索机制	主要定位
MC ε-Greedy	同样使用 Monte Carlo 回报平均	通常 every-visit	策略内部持续随机探索	去除 Exploring Starts，更接近实际学习方式

核心结论

三种算法的演进逻辑是：**MC Basic 说明原理 → Exploring Starts 提高样本利用率 → ε-greedy 用软策略解决起点探索难题**。

12 Monte Carlo 与动态规划、TD 方法的区别

方法	是否需要模型	更新目标	何时更新
动态规划 (DP)	需要	对所有下一状态求期望的 Bellman 目标	可做系统性 sweep
Monte Carlo	不需要	episode 的实际完整回报 G_t	通常等待 episode 结束
Temporal Difference	不需要	奖励加下一状态当前估计，如 $R_{t+1} + \gamma V(S_{t+1})$	每一步即可更新

Monte Carlo 的特点可以概括为：

- **无模型**：直接使用经验；
- **不自举（no bootstrapping）**：目标是实际完整回报，而不是依赖下一状态的当前价值估计；
- **通常适合 episodic tasks**：需要知道一段轨迹的后续奖励；
- **方差可能较大**：同一状态动作对的实际回报会随随机轨迹明显变化。

13 初学者最容易产生的五个误解

1. **“Monte Carlo 就是随机选择动作。”**

   错误。随机探索只是策略的一部分；Monte Carlo 的本质是用采样回报估计期望。

2. **“一条回报就是动作价值。”**

   不准确。一条回报只是动作价值的一个随机样本；多次回报平均值才是估计。

3. **“episode 越长永远越好。”**

   不一定。过短会遗漏远期奖励；过长会增加计算量和回报方差，还可能带来无关轨迹。

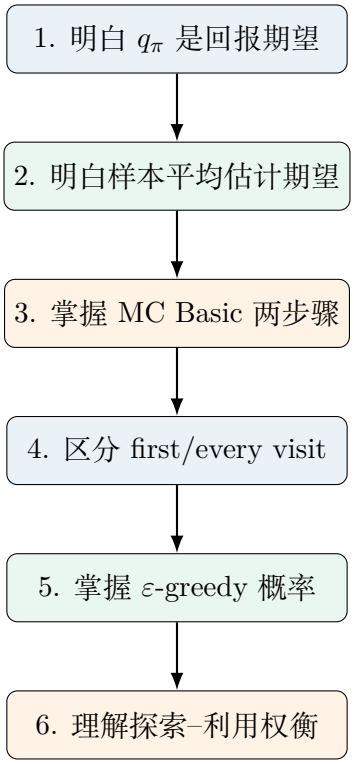
4. **“ε 越大，学习越好。”**

   不一定。ε 大增强探索，但会降低利用和最终执行性能。

5. **“MC ε-Greedy 一定得到完全贪心最优策略。”**

   固定 $\varepsilon > 0$ 时，它得到的是给定软策略集合中的最优策略，不是完全确定性的贪心策略。

14 建议的快速学习顺序



学习时不必一开始背诵全部伪代码。先确认每行代码属于以下哪类操作：

$$\boxed{\text{生成轨迹}} \quad \rightarrow \quad \boxed{\text{反向计算回报}} \quad \rightarrow \quad \boxed{\text{累计并平均}} \quad \rightarrow \quad \boxed{\text{改进策略}}.$$

15 自测题与参考答案

题 1

为什么动作价值可以使用 Monte Carlo 方法估计?

题 2

一条 episode 的奖励为 $R_1 = 1, R_2 = 0, R_3 = 2$，折扣因子 $\gamma = 0.5$。计算 G_0, G_1, G_2。

题 3

某状态有 5 个动作，$\varepsilon = 0.1$。ε-greedy 策略选择贪心动作和每个非贪心动作的概率分别是多少?

题 4

为什么 every-visit 通常比 initial-visit 样本效率高?

题 5

在真实机械臂实验中，为什么 Exploring Starts 条件难以满足？

参考答案

1. 因为 $q_\pi(s,a)$ 定义为从 (s,a) 出发的回报期望，而期望可由多次采样回报的平均值近似。
2. $G_2 = 2$，$G_1 = 0 + 0.5 \times 2 = 1$，$G_0 = 1 + 0.5 \times 1 = 1.5$。
3. 贪心动作概率 $1 - 0.1 + 0.1/5 = 0.92$；每个非贪心动作概率 $0.1/5 = 0.02$。
4. 它会利用 episode 中每一次状态动作访问，而不是只使用初始访问，因此同一条轨迹产生更多更新信息。
5. 真实系统不能任意初始化到所有状态，也不能安全地从任意动作开始；硬件状态、工作空间和安全约束均会限制起点选择。

16 一页总结

核心结论

1. Monte Carlo 方法用随机样本的平均值估计期望。
2. 动作价值 $q_\pi(s,a)$ 是从 (s,a) 出发的回报期望，因此可以通过 episode 回报平均值估计。
3. MC Basic 把策略迭代中的模型计算替换成样本估计。
4. First-visit 和 every-visit 提高了单条 episode 的利用率。
5. Exploring Starts 要求所有状态动作对都能作为起点被充分探索，现实中较难满足。
6. ε-greedy 通过在策略内部保留随机动作概率来持续探索。
7. ε 大：探索强、利用弱；ε 小：利用强、探索弱。
8. episode 太短或奖励过于稀疏时，远期有效奖励无法传递到较早状态。
9. MC 使用完整实际回报，不依赖模型，也不使用下一状态价值进行自举。

掌握标准：看到一段 MC 伪代码时，能够指出其轨迹生成、回报计算、价值平均、策略改进和探索机制分别在哪里。