第 7 章：Temporal-Difference Methods

初学者快速认识与理解指南



核心结论

本章只需要先抓住一句话：

$$\text{TD 更新} = \text{当前估计} + \text{学习率} \times (\text{TD target} - \text{当前估计}).$$

Sarsa、n-step Sarsa 与 Q-learning 的外形几乎相同；真正决定“在评价谁、解哪个方程”的，是 target 中放入下一动作、若干步奖励，还是最大动作价值。

基于所给 Chapter 7（原书第 125–150 页）与 L7 slides 整理

目标：约 60–75 分钟建立 TD 方法完整知识框架

目录

1 先回答：TD 比 Monte Carlo 多做了什么？ 2
1.1 本章算法地图 . . . 2

2 状态价值 TD：最基本的一步更新 2
2.1 算法公式 . . . 2
2.2 TD error 的正负号必须先约定 . . . 3
2.3 终止状态怎样处理? . . . 3

3 TD 为什么是随机逼近算法？ 3
3.1 固定策略评价的收敛条件 . . . 4

4 TD 与 MC：四个维度不要混 4

5 Sarsa：把状态价值更新换成动作价值更新 5
5.1 公式与名字 . . . 5
5.2 Sarsa 解哪个方程? . . . 5

6 用 Sarsa 学策略：评价与改进交替发生 5
6.1 Expected Sarsa . . . 6

7 n-step Sarsa：连接一步 TD 与 MC 6

8 Q-learning：直接逼近最优动作价值 6
8.1 算法公式 . . . 6
8.2 它解的是 Bellman 最优方程 . . . 7
8.3 表格型 Q-learning 何时收敛? . . . 7

9 on-policy、off-policy 与 online、offline 7
9.1 先定义两类策略 . . . 7
9.2 Q-learning 为什么能使用其他策略的数据? . . . 8
9.3 教材中“on-policy version of Q-learning”的术语说明 . . . 8

10 五类 target 的统一视角 8

11 可直接照着读的伪代码骨架 9

12 初学者最容易产生的八个误解 10

13 建议的快速学习顺序 11

14 自测题与参考答案 11

15 一页总结 12

内容核对说明 12

1 先回答：TD 比 Monte Carlo 多做了什么？

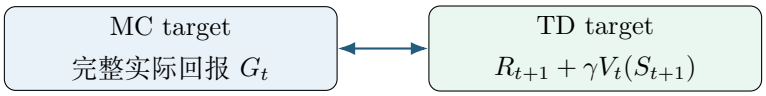
L5 的 MC 方法用完整回报

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots$$

作为价值样本，因此通常要等 episode 后面的奖励出现。TD 不等待完整回报，而在看到一步经验 (S_t, R_{t+1}, S_{t+1}) 后，用

$$R_{t+1} + \gamma V_t(S_{t+1})$$

暂时代替未知的完整未来。这种“用已有估计更新当前估计”称为 **自举（bootstrapping）**。



核心结论

TD 与 MC 都是无模型方法：它们使用交互样本，而不需要显式知道转移概率和奖励分布。TD 的新增思想是**一步采样加自举**，因此可以增量更新，也能处理没有自然终点的 continuing task。

1.1 本章算法地图

算法	估计对象	数学目标
状态价值 TD	$v_\pi(s)$	解固定策略的 Bellman 期望方程
Sarsa	$q_\pi(s,a)$	解固定策略的动作价值 Bellman 方程
n-step Sarsa	$q_\pi(s,a)$	用 n 步 target 解同一个 Bellman 方程
Q-learning	$q_*(s,a)$	直接解 Bellman 最优方程

2 状态价值 TD：最基本的一步更新

2.1 算法公式

给定固定策略 π，目标是估计

$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s].$$

沿策略 π 得到一步经验 (s_t, r_{t+1}, s_{t+1}) 后，定义

$$\overline{v}_t = r_{t+1} + \gamma v_t(s_{t+1})$$

为 TD target。教材公式写为

$$\boxed{v_{t+1}(s_t) = v_t(s_t) - \alpha_t(s_t)\left[v_t(s_t) - \overline{v}_t\right]}.$$

未访问状态保持不变：

$$v_{t+1}(s) = v_t(s), \qquad s \neq s_t.$$

直观理解

若 target 大于当前估计，就向上修正；若 target 小于当前估计，就向下修正。当 $0 < \alpha_t < 1$ 时，新估计是二者的凸组合：

$$v_{t+1}(s_t) = (1 - \alpha_t)v_t(s_t) + \alpha_t \overline{v}_t.$$

2.2 TD error 的正负号必须先约定

教材定义“当前估计减 target”：

$$\delta_t^{\text{book}} = v_t(s_t) - \overline{v}_t, \qquad v_{t+1} = v_t - \alpha_t \delta_t^{\text{book}}.$$

许多 RL 教材和代码则定义“target 减当前估计”：

$$\delta_t^{+} = \overline{v}_t - v_t(s_t), \qquad v_{t+1} = v_t + \alpha_t \delta_t^{+}.$$

两者满足 $\delta_t^{+} = -\delta_t^{\text{book}}$，更新完全等价。本文后续优先使用更贴合“误差修正”直觉的 δ_t^{+}。

容易混淆

只看符号“$+\alpha\delta$”或“$-\alpha\delta$”无法判断公式是否正确；必须同时查看作者如何定义 δ。把一个来源的 TD error 定义和另一个来源的更新号混用，才会真正把学习方向写反。

2.3 终止状态怎样处理？

若 s_{t+1} 是终止状态，通常令其后续价值为零：

$$v_t(s_{t+1}) = 0, \qquad \overline{v}_t = r_{t+1}.$$

这表示到达终止状态后不再产生未来回报，而不是把到达终止状态的即时奖励删掉。

一次状态价值 TD 更新

设 $v_t(s_t) = 4$、$r_{t+1} = 2$、$v_t(s_{t+1}) = 5$、$\gamma = 0.9$、$\alpha = 0.1$。则

$$\overline{v}_t = 2 + 0.9 \times 5 = 6.5, \qquad \delta_t^{+} = 6.5 - 4 = 2.5,$$

$$v_{t+1}(s_t) = 4 + 0.1 \times 2.5 = 4.25.$$

新值没有直接跳到 6.5，而是向 target 移动了距离的 10%。

3 TD 为什么是随机逼近算法？

Bellman 期望方程可以写成

$$v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s].$$

把右侧移到左侧，定义

$$g(v_\pi(s)) = v_\pi(s) - \mathbb{E}_\pi[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s].$$

求价值等价于求 $g(v_\pi(s)) = 0$。一步经验给出带噪观测

$$\widetilde{g} = v_t(s_t) - [r_{t+1} + \gamma v_t(s_{t+1})].$$

把它代入 L6 的 Robbins–Monro 更新 $v_{t+1} = v_t - \alpha_t \widetilde{g}$，正好得到 TD。

核心结论

TD 不是凭经验拼出来的启发式公式。教材的核心解释是：它用一步随机样本，对 Bellman 方程的根做随机逼近。

3.1 固定策略评价的收敛条件

教材 Theorem 7.1 指出：对给定策略 π，若对所有 $s \in \mathcal{S}$ 都有

$$\sum_t \alpha_t(s) = \infty, \qquad \sum_t \alpha_t^2(s) < \infty,$$

则表格型 TD 的 $v_t(s)$ 几乎必然收敛到 $v_\pi(s)$。这里未访问时 $\alpha_t(s) = 0$，所以第一条条件还隐含：每个需要估计的状态必须被访问足够多次。该结论处于教材默认的有限状态、有界奖励与折扣设定中。

容易混淆

这是**固定策略评价**的定理。控制算法中策略在学习过程中不断变化，不能直接把此定理当作“任意常步长 Sarsa 控制一定收敛到最优策略”的证明。教材也解释了：实践中常用小常步长来跟踪这个非平稳目标，代价是最终估计可能轻微波动。

4 TD 与 MC：四个维度不要混

维度	TD	Monte Carlo
更新时间	每得到一步经验即可更新	通常等待完整 episode，得到 G_t 后更新
任务类型	episodic 与 continuing 均可	经典形式更适合有终止/可截断的 episodic task
target	$R_{t+1} + \gamma V_t(S_{t+1})$，使用自举	实际完整回报 G_t，不自举
统计特征	target 涉及较少未来随机量，通常方差较低，但受当前估计影响	回报包含许多未来随机量，通常方差较高，但不依赖下一状态估计

专业核对

持续更新/等待 episode 是**更新时间**；on-policy/off-policy 是**数据策略与学习目标的关系**；online/offline 是**是否边交互边学习，还是只用预先收集的数据**。这三组概念不在同一个维度，不能互相替代。

5 Sarsa：把状态价值更新换成动作价值更新

5.1 公式与名字

给定策略 π，Sarsa 用经验

$$(s_t, a_t, r_{t+1}, s_{t+1}, a_{t+1})$$

估计 $q_\pi(s,a)$：

$$\boxed{q_{t+1}(s_t,a_t) = q_t(s_t,a_t) + \alpha_t\left[r_{t+1} + \gamma q_t(s_{t+1},a_{t+1}) - q_t(s_t,a_t)\right]}.$$

它每次需要 State–Action–Reward–State–Action，因而得名 **Sarsa**。其他未访问的状态–动作对保持不变。

Sarsa 的 target 是

$$\bar{q}_t^{\text{Sarsa}} = r_{t+1} + \gamma q_t(s_{t+1}, a_{t+1}),$$

其中 a_{t+1} 是策略实际在下一状态选出的动作。

5.2 Sarsa 解哪个方程？

固定策略 π 的动作价值满足

$$q_\pi(s,a) = \mathbb{E}_\pi[R_{t+1} + \gamma q_\pi(S_{t+1}, A_{t+1}) \mid S_t = s, A_t = a].$$

Sarsa 用一步样本逼近这个 Bellman 方程。教材 Theorem 7.2 给出的固定策略评价条件与 TD 类似：对每个 (s,a)，需有

$$\sum_t \alpha_t(s,a) = \infty, \qquad \sum_t \alpha_t^2(s,a) < \infty.$$

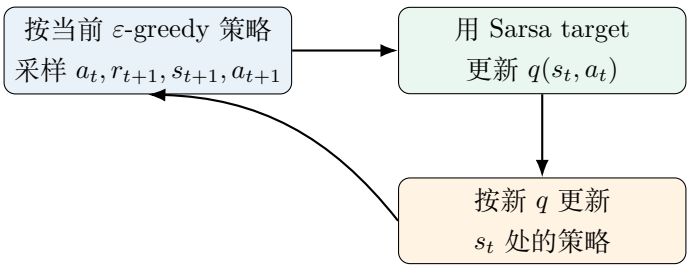
这要求每个需要准确估计的状态–动作对都被充分访问。

6 用 Sarsa 学策略：评价与改进交替发生

若只运行上一节公式，得到的是给定策略的 q_π。为了寻找好策略，每更新一个 $q(s_t,a_t)$，就把 s_t 处的策略更新为相对当前 q 的 ε-greedy 策略。先按约定从并列最大动作中选出一个 $a^\star(s) \in \arg\max_b q(s,b)$，则

$$\pi(a \mid s) = \begin{cases} 1 - \varepsilon + \dfrac{\varepsilon}{|\mathcal{A}(s)|}, & a = a^\star(s), \\ \dfrac{\varepsilon}{|\mathcal{A}(s)|}, & \text{其他动作}. \end{cases}$$

随后继续用这个策略生成 a_{t+1}。这就是广义策略迭代：评价不必彻底完成，策略改进与价值修正可以交织进行。



为什么 Sarsa 是 on-policy？

Sarsa target 中的 a_{t+1} 来自正在执行的行为策略；算法评价并不断改进的也正是这个策略。因此行为策略与被评价/改进的目标策略相同。为了保证探索，控制实现通常让它保持 ε-greedy。

6.1 Expected Sarsa

教材 Box 7.4 给出 Expected Sarsa，把实际抽到的 a_{t+1} 换成策略下的动作价值期望：

$$\bar{q}_t^{\text{ExpSarsa}} = r_{t+1} + \gamma \sum_a \pi_t(a \mid s_{t+1}) q_t(s_{t+1}, a).$$

它仍在解固定策略的 Bellman 方程。由于对下一动作的随机性做了精确平均，通常能降低 target 的方差，但每一步需要遍历下一状态的动作集合。

7 n-step Sarsa：连接一步 TD 与 MC

对动作价值，n 步 target 为

$$\boxed{G_t^{(n)} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{n-1} R_{t+n} + \gamma^n q_t(S_{t+n}, A_{t+n})}.$$

相应更新为

$$q(s_t, a_t) \leftarrow q(s_t, a_t) + \alpha \left[G_t^{(n)} - q(s_t, a_t) \right].$$

因为要等 $R_{t+n}, S_{t+n}, A_{t+n}$ 出现，时刻 t 的状态–动作对通常到 $t+n$ 时才能更新。

- $n = 1$：target 退化为 $R_{t+1} + \gamma q(S_{t+1}, A_{t+1})$，即 Sarsa；
- 在 episodic task 中，让 n 延伸到 episode 结束：bootstrap 项消失，target 变成 MC 回报；
- n 较小：更依赖当前价值估计，通常偏差较大、方差较低；
- n 较大：纳入更多实际奖励，通常偏差较小、方差较高。

“MC 是 $n = \infty$” 应怎样准确理解？

教材用 $n = \infty$ 表示不再在有限未来位置自举，而是一直展开完整回报。对有限 episode，实际只需展开到终止时刻；若提前终止，终止后的 bootstrap 价值取零。教材在统一表达中令 $\alpha = 1$ 可得到“用单次回报直接赋值”的 MC 形式；采用样本平均的 MC 则可使用访问次数对应的递减步长，而不必固定为 1。

8 Q-learning：直接逼近最优动作价值

8.1 算法公式

Q-learning 更新为

$$\boxed{q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t \left[r_{t+1} + \gamma \max_a q_t(s_{t+1}, a) - q_t(s_t, a_t) \right]}.$$

它与 Sarsa 的外形只差 target：

$$q_t^Q = r_{t+1} + \gamma \max_a q_t(s_{t+1}, a).$$

下一状态真正执行了哪个动作，不进入这个 target。

8.2 它解的是 Bellman 最优方程

最优动作价值满足

$$q_*(s,a) = \mathbb{E}\left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a\right].$$

Q-learning 用样本 r_{t+1}, s_{t+1} 对这个方程做随机逼近，所以它直接估计 q_*，最终可取

$$\pi_*(s) \in \arg\max_a q_*(s,a).$$

8.3 表格型 Q-learning 何时收敛？

教材指出，Q-learning 的收敛分析与状态价值 TD 的思路相似，并引用 Chapter 6 的随机逼近扩展。在教材的有限、折扣、表格型设定下，关键要求仍是：每个状态–动作对被访问充分多次，且其步长满足

$$\sum_t \alpha_t(s,a) = \infty, \qquad \sum_t \alpha_t^2(s,a) < \infty.$$

在相应有界性条件下，估计收敛到 Bellman 最优方程的解 q_*。这个结论针对表格型算法，不能直接外推为“使用任意非线性函数逼近器的 Q-learning 都保证收敛”。

同一条经验下 Sarsa 与 Q-learning 的差别

设当前 $q(s_t, a_t) = 2$，$r_{t+1} = 1$，$\gamma = 0.9$，$\alpha = 0.2$。下一状态两个动作的估计分别为 3 和 4，行为策略实际选中了价值为 3 的动作。

$$\text{Sarsa target} = 1 + 0.9 \times 3 = 3.7, \quad q_{\text{new}} = 2 + 0.2(3.7 - 2) = 2.34,$$
$$\text{Q-learning target} = 1 + 0.9 \times 4 = 4.6, \quad q_{\text{new}} = 2 + 0.2(4.6 - 2) = 2.52.$$

Sarsa 学“接下来实际按行为策略做什么”；Q-learning 学“接下来若取当前最大动作价值会怎样”。

9 on-policy、off-policy 与 online、offline

9.1 先定义两类策略

- **行为策略（behavior policy）π_b：**负责产生经验中的动作；
- **目标策略（target policy）π_T：**算法希望评价或逼近的策略。

  当 $\pi_b = \pi_T$ 时称为 on-policy；两者可以不同时称为 off-policy。

算法	行为策略如何进入样本	target 实际评价什么
Sarsa	A_t, A_{t+1} 都由当前行为策略生成	同一策略的 q_π，因此是 on-policy
Q-learning	A_t 可由探索性行为策略生成	下一步使用 $\max_a q(S_{t+1}, a)$，对应贪心目标，因此标准分类为 off-policy

9.2 Q-learning 为什么能使用其他策略的数据？

给定 (s_t, a_t) 后，环境产生 (r_{t+1}, s_{t+1})；Q-learning target 不需要行为策略在 s_{t+1} 实际选出的 a_{t+1}。因此可以用探索性很强的 π_b 收集数据，同时学习贪心目标。

off-policy 不等于“随便什么旧数据都保证学好”

行为策略仍必须提供充分覆盖：如果某个状态–动作对从未被访问，表中对应的 $q(s, a)$ 就没有样本可以更新。教材的示例也显示，行为策略探索性变弱时，Q-learning 的学习速度会显著下降。

9.3 教材中“on-policy version of Q-learning”的术语说明

教材 Section 7.4.3 把“用当前 ε-greedy 策略边交互边更新”的实现称为 Q-learning 的 on-policy version，又把先由独立行为策略产生经验的实现称为 off-policy version。这描述的是**采样实现是否使用当前策略**。但 Q-learning 的 backup 始终使用 $\max_a q(s', a)$；当行为策略为 ε-greedy 而 target 为 greedy 时，标准 RL 分类仍把这个更新称为 off-policy TD control。

专业核对

为避免术语冲突，检查两个问题最可靠：

1. 数据中的下一动作是谁生成的？
2. target 用实际下一动作的价值，还是用最大/期望动作价值？

同时，online/offline 只说明是否边与环境交互边学习：off-policy 算法既可在线使用，也可处理预先收集的数据。

10 五类 target 的统一视角

所有动作价值更新都可写成

$$\boxed{q_{t+1}(s_t, a_t) = q_t(s_t, a_t) + \alpha_t\big[\bar{q}_t - q_t(s_t, a_t)\big]}.$$

方法	target $\bar{q}_t$	所解方程/性质
Sarsa	$r_{t+1} + \gamma q_t(s_{t+1}, a_{t+1})$	策略 Bellman 方程；on-policy

方法	target $\bar{q}_t$	所解方程/性质
Expected Sarsa	$r_{t+1} + \gamma \sum_a \pi_t(a \mid s_{t+1}) q_t(s_{t+1}, a)$	策略 Bellman 方程；对下一动作求期望
n-step Sarsa	$r_{t+1} + \gamma r_{t+2} + \cdots + \gamma^{n-1} r_{t+n} + \gamma^n q_t(s_{t+n}, a_{t+n})$	策略 Bellman 方程；多步自举
Q-learning	$r_{t+1} + \gamma \max_a q_t(s_{t+1}, a)$	Bellman 最优方程；off-policy backup
Monte Carlo	$r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots$	完整回报；不自举

核心结论

比较算法时，先遮住算法名字，只看 target：“实际下一动作”对应 Sarsa，“策略期望”对应 Expected Sarsa，“若干实际奖励后再自举”对应 n-step Sarsa，“下一状态取最大值”对应 Q-learning，“一直展开到 episode 结束”对应 MC。

11 可直接照着读的伪代码骨架

Sarsa 控制

Sarsa：每个 episode

1. 初始化 S；按当前 ε-greedy 策略选 A。
2. 执行 A，观察 R, S'；若 S' 非终止，按同一策略选 A'。
3. 计算 $\bar{q} = R + \gamma q(S', A')$；终止时 bootstrap 项为零。
4. 更新 $q(S, A) \leftarrow q(S, A) + \alpha[\bar{q} - q(S, A)]$。
5. 令 $S \leftarrow S'$、$A \leftarrow A'$，直至终止。

Q-learning 控制

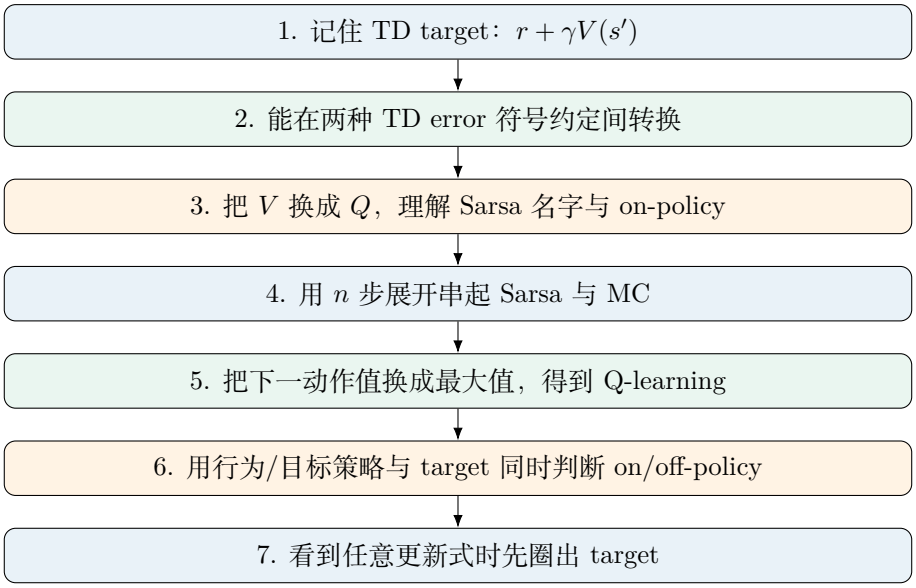
Q-learning：每个 episode

1. 初始化 S；由具有探索性的行为策略选 A。
2. 执行 A，观察 R, S'。
3. 计算 $\overline{q} = R + \gamma \max_a q(S', a)$；终止时最大值项取零。
4. 更新 $q(S, A) \leftarrow q(S, A) + \alpha[\overline{q} - q(S, A)]$。
5. 令 $S \leftarrow S'$，继续由行为策略选动作，直至终止。

12 初学者最容易产生的八个误解

1. **“TD target 就是真实价值。”**
   不是。它是由一次奖励和当前估计构成的随机目标；只有在期望和收敛意义下逼近正确价值。
2. **“自举就是使用自己的当前估计，所以一定会发散。”**
   不对。表格型、固定策略、适当步长与覆盖条件下，教材给出了 TD/Sarsa 评价的收敛结论。
3. **“TD error 必须定义成 target 减估计。”**
   两种符号约定都存在；定义与更新号配套即可。
4. **“Sarsa 只要有更新式就会自动找到最优策略。”**
   固定策略 Sarsa 只做评价；控制还需要策略改进与持续探索。
5. **“n 越大一定越好。”**
   不一定。更大的 n 通常减小自举偏差，却引入更多随机奖励、增加等待和方差。
6. **“Q-learning target 使用行为策略实际选出的下一动作。”**
   错误。它使用下一状态所有动作估计的最大值。
7. **“off-policy 意味着不能在线学习。”**
   错误。off-policy 说明行为策略与目标 backup 可不同；算法仍可边交互边更新。
8. **“行为策略可以完全不探索。”**
   不行。没有覆盖到的状态–动作对无法靠 Q-learning 凭空得到正确估计。

13 建议的快速学习顺序



14 自测题与参考答案

题目

1. 若 $v(s)=3$、$r=1$、$v(s')=4$、$\gamma=0.5$、$\alpha=0.2$，用正号约定计算 TD target、TD error 与新值。
2. 教材把 TD error 定义为 $v-\overline{v}$。若改用 $\overline{v}-v$，更新号应怎样变化?
3. 写出 Sarsa 与 Q-learning target，并指出二者唯一的结构差别。
4. 三步 Sarsa 的 target 包含哪些项?
5. 为什么固定策略 Sarsa 的收敛条件要求每个 (s,a) 被充分访问?
6. 行为策略为 ε-greedy、backup 使用 $\max_a q(s',a)$。按标准分类属于 on-policy 还是 off-policy?

参考答案

1. $\overline{v}=1+0.5\times 4=3$，$\delta^{+}=3-3=0$，新值仍为 3。
2. 从 $v\leftarrow v-\alpha(v-\overline{v})$ 改成 $v\leftarrow v+\alpha(\overline{v}-v)$。
3. Sarsa：$r+\gamma q(s',a')$；Q-learning：$r+\gamma\max_a q(s',a)$。差别是使用实际下一动作的价值，还是下一状态的最大动作价值。
4. $r_{t+1}+\gamma r_{t+2}+\gamma^2 r_{t+3}+\gamma^3 q(s_{t+3},a_{t+3})$；若此前终止，则不再加 bootstrap 项。
5. 未访问的表项不会更新；没有足够样本就无法把该表项的估计误差压到零。
6. off-policy：行为策略会探索，而 backup 对应贪心目标。

15 一页总结

核心结论

1. TD 用一步经验构造 $R_{t+1}+\gamma V_t(S_{t+1})$，无需等待完整 episode。
2. TD 是对 Bellman 方程的随机逼近；更新只改变当前访问的表项。
3. TD error 有两种相反符号约定，必须与更新中的正负号配套。
4. Sarsa 的数据是 (S, A, R, S', A')，target 使用行为策略实际选出的下一动作。
5. Sarsa 控制通过价值更新与 ε-greedy 策略改进交替进行，属于 on-policy。
6. n-step Sarsa 在一步 Sarsa 与完整回报 MC 之间调节自举程度及偏差–方差。
7. Q-learning 的 target 使用 $\max_a Q(S', a)$，直接逼近 Bellman 最优方程。
8. Q-learning 的 backup 是 off-policy；行为策略必须提供充分的状态–动作覆盖。
9. online/offline 描述数据收集时机，on/off-policy 描述行为策略与学习目标，二者不能混用。
10. 比较 TD 算法最有效的方法，是先找出各自的 target。

掌握标准：给出一条经验和一组 V/Q 数值，能够手算 TD、Sarsa、Expected Sarsa、n-step Sarsa 与 Q-learning 的 target，并据此判断所解方程和 on/off-policy 性质。

内容核对说明

本资料的定义、公式、算法结构与定理条件以工作区内的 Book 目录为依据：

`Book-Mathematical-Foundation-of-Reinforcement-Learning-main`

具体核对文件如下：

- `3 - Chapter 7 Temporal-Difference Methods.pdf`（原书第 125–150 页）；
- `Lecture slides/slidesContinuouslyUpdated/L7-Temporal-Difference Learning.pdf`；
- `Lecture slides/slidesForMyLectureVideos/L7-Temporal-difference learning.pdf`；
- `5 - Errata for the Springer version.pdf`（该勘误表未列出 Chapter 7 修正，且注明 GitHub PDF 已吸收已知勘误）。

专业性处理包括：同时列出教材与常见代码中的两种 TD error 符号；明确固定策略评价定理不自动等于控制算法定理；补全终止状态的零 bootstrap 约定；并区分教材所说的 Q-learning 采样“实现版本”与按 target 判断的标准 off-policy 分类。