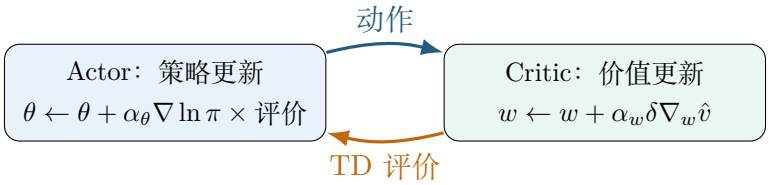
第 10 章：Actor–Critic Methods

初学者快速认识与理解指南



核心结论

Actor–critic 把 L9 的策略梯度和 L8 的 TD 函数近似放在同一个循环中：actor 根据 critic 的评价改变行为，critic 又持续评价 actor 当前产生的行为。baseline/A2C、importance sampling 与 deterministic policy gradient 都是这一结构的扩展。

基于 Book Chapter 10（原书第 215–236 页）与 L10 连续更新 slides 整理

覆盖：QAC、baseline/A2C、off-policy AC、DPG 与确定性 AC

目录

10 L10：Actor–Critic Methods——策略与价值协同学习 **2**
10.1 最简单的 Q Actor–Critic（QAC） . . . 2
10.2 baseline invariance：为什么减去基线不改变真梯度 . . . 2
10.3 baseline 为什么有用：降低随机梯度方差 . . . 3
10.4 优势函数：评价动作相对平均水平好多少 . . . 3
10.5 用 TD error 近似优势：A2C 的关键一步 . . . 3
10.6 REINFORCE、QAC 与 A2C 的关系 . . . 4
10.7 重要性采样：用另一个分布的样本估计期望 . . . 4
10.8 Off-policy Actor–Critic . . . 5
10.9 确定性策略梯度：策略直接输出动作 . . . 5
10.10 Deterministic Actor–Critic 算法 . . . 6
10.11 四类 Actor–Critic 的统一比较 . . . 6
10.12 初学者最容易产生的九个误解 . . . 6
10.13 自测题与参考答案 . . . 7
10.14 一页总结 . . . 8

内容核对说明 **8**

10 L10：Actor–Critic Methods——策略与价值协同学习

L9 的策略梯度更新需要 $q_\pi(S,A)$。若用完整回报估计它，就是 REINFORCE；若改用 TD 方法持续学习价值函数，就得到 actor–critic：

- **actor** 用参数 θ 表示并更新策略，负责“怎样行动”；
- **critic** 用参数 w 表示并更新价值，负责“评价 actor 的行动”。

Actor–Critic 的最小结构

$$\text{actor:} quad \theta \leftarrow \theta + alpha_\theta \nabla_\theta \ln \pi(A \mid S,\theta) \times \text{价值信号},$$

$$\text{critic:} quad w \leftarrow w + \alpha_w(\text{TD target} - \text{当前价值})\nabla_w \hat{v} \text{ 或} \nabla_w \hat{q}.$$

它仍属于策略梯度方法，只是用 TD 函数近似实现价值估计部分。

10.1 最简单的 Q Actor–Critic（QAC）

QAC 的 critic 用带函数近似的 Sarsa 学习 $q_\pi(s,a)$。在时间 t：

$$\delta_t^Q = R_{t+1} + \gamma \hat{q}(S_{t+1}, A_{t+1}, w_t) - \hat{q}(S_t, A_t, w_t).$$

actor 与 critic 分别更新为

$$\boxed{\theta_{t+1} = \theta_t + \alpha_\theta \nabla_\theta \ln \pi(A_t \mid S_t, \theta_t) \hat{q}(S_t, A_t, w_t)},$$

$$\boxed{w_{t+1} = w_t + \alpha_w \delta_t^Q \nabla_w \hat{q}(S_t, A_t, w_t)}.$$

A_t 与 A_{t+1} 都按当前策略产生，所以教材中的基础 QAC 是 on-policy。

直观理解

QAC 只把 REINFORCE 的 G_t 换成持续更新的 $\hat{q}(S_t, A_t, w)$。因此不必等 episode 结束，方差通常也比完整回报低；代价是 critic 使用 bootstrap，会受当前价值近似误差影响。

10.2 baseline invariance：为什么减去基线不改变真梯度

对任意只依赖状态、不依赖当前动作的标量基线 $b(S)$，有

$$\boxed{\mathbb{E}[\nabla_\theta \ln \pi(A \mid S,\theta) q_\pi(S,A)] = \mathbb{E}[\nabla_\theta \ln \pi(A \mid S,\theta)(q_\pi(S,A) - b(S))]}.$$

原因是在固定 $S = s$ 时

$$\begin{aligned}\mathbb{E}_{A\sim\pi}[\nabla_\theta \ln \pi(A \mid s,\theta) b(s)] &= b(s) \sum_a \nabla_\theta \pi(a \mid s,\theta) \\ &= b(s) \nabla_\theta \sum_a \pi(a \mid s,\theta) = 0.\end{aligned}$$

baseline 可以依赖状态，但基础结论不允许依赖所采动作

若直接使用 $b(S,A)$，上面的动作求和一般不再为零，可能改变梯度期望。“减去任意东西都不偏”是错误说法；教材的 baseline invariance 针对 $b(S)$。

10.3 baseline 为什么有用：降低随机梯度方差

令

$$X = \nabla_\theta \ln \pi(A \mid S, \theta)[q_\pi(S, A) - b(S)].$$

改变 b 不改变 $\mathbb{E}[X]$，却会改变 $\mathrm{Var}(X)$。教材给出的逐状态最优基线为

$$b^*(s) = \frac{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A \mid s, \theta)\|^2 q_\pi(s, A)]}{\mathbb{E}_{A\sim\pi}[\|\nabla_\theta \ln \pi(A \mid s, \theta)\|^2]}.$$

它计算复杂。去掉梯度范数权重后得到实用基线

$$b(s) = \mathbb{E}_{A\sim\pi}[q_\pi(s, A)] = v_\pi(s).$$

专业核对

baseline 的核心作用是**减方差而不改期望**，不是把梯度“变得更大”。$v_\pi(s)$ 是简洁且有清楚含义的基线，但教材明确指出它是对最优基线的实用近似，并非一般情况下的精确方差最优解。

10.4 优势函数：评价动作相对平均水平好多少

定义

$$A_\pi(s, a) = q_\pi(s, a) - v_\pi(s).$$

$v_\pi(s) = \sum_a \pi(a \mid s) q_\pi(s, a)$ 是该状态按当前策略得到的平均动作价值，故：

- $A_\pi(s, a) > 0$：动作优于当前策略在此状态的平均水平；
- $A_\pi(s, a) < 0$：动作劣于平均水平；
- $\mathbb{E}_{A\sim\pi}[A_\pi(s, A)] = 0$。

actor 因而可用

$$\theta \leftarrow \theta + alpha_\theta \nabla_\theta \ln \pi(A \mid S, \theta) A_\pi(S, A)$$

增强正优势动作、削弱负优势动作。

10.5 用 TD error 近似优势：A2C 的关键一步

若 $v = v_\pi$，则在给定 $(S_t = s, A_t = a)$ 时

$$\mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) - v_\pi(S_t) \mid s, a] = A_\pi(s, a).$$

因此单步 TD error

$$\boxed{\delta_t = R_{t+1} + \gamma \hat{v}(S_{t+1}, w_t) - \hat{v}(S_t, w_t)}$$

可作为优势的样本估计，而只需维护一个状态价值 critic。

Advantage Actor–Critic（A2C，也称 TD actor–critic）的更新是

$$\boxed{\begin{aligned} \theta_{t+1} &= \theta_t + \alpha_\theta \delta_t \nabla_\theta \ln \pi(A_t \mid S_t, \theta_t), \\ w_{t+1} &= w_t + \alpha_w \delta_t \nabla_w \hat{v}(S_t, w_t). \end{aligned}}$$

同一个 δ_t，两种不同职责

若 $\delta_t > 0$，actor 增加已选动作的对数概率，critic 同时把 $\hat{v}(S_t, w)$ 向 TD target 上调；若 $\delta_t < 0$，actor 降低已选动作倾向，critic 向下修正当前状态价值。两次更新共享评价信号，但参数、梯度和学习目标不同。

终止状态仍约定后续价值为零：

$$\delta_t = R_{t+1} - \hat{v}(S_t, w_t) qquad (S_{t+1} \text{ 为终止状态}).$$

10.6 REINFORCE、QAC 与 A2C 的关系

方法	actor 的价值信号	critic / 估计方法
REINFORCE	G_t	无独立 TD critic；MC 回报估计 q_π
QAC	$\hat{q}(S_t, A_t, w)$	Sarsa 型动作价值 critic
REINFORCE + baseline	$G_t - \hat{v}(S_t)$	通常仍以 MC 为主
A2C	δ_t	TD 状态价值 critic；δ_t 近似 advantage

容易混淆

A2C 的 δ_t 在 critic 尚未准确时只是优势的近似样本，不等于真实 $A_\pi(S_t, A_t)$。同时，actor 改变策略后 critic 的评价目标也随之变化；这是一套耦合的随机逼近过程，不能把两个更新当成互不相关的监督学习任务。

10.7 重要性采样：用另一个分布的样本估计期望

若目标分布为 p_0、样本来自 p_1，则

$$\mathbb{E}_{X\sim p_0}[f(X)] = \mathbb{E}_{X\sim p_1}\left[\frac{p_0(X)}{p_1(X)} f(X)\right].$$

比率 $p_0(X)/p_1(X)$ 称为 importance weight。成立的覆盖条件是

$$p_0(x) > 0 \Longrightarrow p_1(x) > 0.$$

行为分布不给目标可能事件任何概率时，权重无法补回从未出现的样本。

一个离散重要性采样检查

目标分布 $p_0(+1) = p_0(-1) = 0.5$，行为分布 $p_1(+1) = 0.8, p_1(-1) = 0.2$。来自行为分布的 $+1$ 样本权重为 $0.5/0.8$，-1 样本权重为 $0.5/0.2$。稀有的 -1 样本被放大，这能修正偏差，也说明 importance weight 可能带来较大方差。

10.8 Off-policy Actor–Critic

设行为策略为 β、目标策略为 π_θ，动作重要性权重为

$$\rho_t = \frac{\pi(A_t \mid S_t, \theta_t)}{\beta(A_t \mid S_t)}.$$

教材 Theorem 10.1 在折扣情形给出

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\rho, A\sim\beta}\left[\frac{\pi(A \mid S, \theta)}{\beta(A \mid S)} \nabla_\theta \ln \pi(A \mid S, \theta) q_\pi(S, A)\right],$$

其中状态分布 ρ 是从行为策略平稳分布 d_β 出发、再按目标策略转移得到的折扣总访问分布。这说明不仅动作分布需要说明，状态分布也属于定理的一部分。

用 v_π baseline 和 TD error 后，教材 Algorithm 10.3 为

$$\begin{aligned}
\delta_t &= R_{t+1} + \gamma \hat{v}(S_{t+1}, w_t) - \hat{v}(S_t, w_t), \\
\theta_{t+1} &= \theta_t + \alpha_\theta \rho_t \delta_t \nabla_\theta \ln \pi(A_t \mid S_t, \theta_t), \\
w_{t+1} &= w_t + \alpha_w \rho_t \delta_t \nabla_w \hat{v}(S_t, w_t).
\end{aligned}$$

勘误表对应的时间下标

Chapter 10 勘误明确把 off-policy actor 更新中的策略参数统一为 θ_t：权重分子和 $\nabla \ln \pi$ 都应使用当前参数 θ_t。本文采用该修正版，并按教材 Algorithm 10.3 在 actor 与 critic 两边都乘 ρ_t。

重要性采样修正分布，但可能放大方差

当 $\beta(A_t \mid S_t)$ 很小时，ρ_t 可能很大。基础公式的无偏/一致性直觉不能自动等价为稳定、低方差的有限样本训练；同时必须保证行为策略覆盖目标策略支持集。

10.9 确定性策略梯度：策略直接输出动作

随机策略输出动作分布 $\pi(a \mid s, \theta)$；确定性策略直接输出动作

$$a = \mu(s, \theta).$$

教材 Theorem 10.2 将确定性策略梯度写成

$$\nabla_\theta J(\theta) = \mathbb{E}_{S\sim\eta}\left[\nabla_\theta \mu(S, \theta) \nabla_a q_\mu(S, a)\big|_{a=\mu(S,\theta)}\right].$$

这是链式法则：先看 critic 认为动作往哪个方向改变会增大 q，再通过 actor 的 Jacobian 把动作方向传回策略参数。

直观理解

$\nabla_a q_\mu(s, a)$ 回答“动作稍微向哪里移动会更好”；$\nabla_\theta \mu(s, \theta)$ 回答“怎样改参数才能让输出动作向那里移动”。二者相乘就是 deterministic actor 的更新方向。

确定性梯度中没有动作随机变量 A，教材据此说明它天然适合 off-policy 学习，也适合连续动作空间。状态分布 η 仍随具体指标而定：折扣平均价值对应折扣总访问分布，不折扣平均奖励对应 d_μ。

10.10 Deterministic Actor–Critic 算法

行为策略 β 负责探索并生成 $(S_t, A_t, R_{t+1}, S_{t+1})$；目标 actor 为 μ。教材 Algorithm 10.4 使用

$$\delta_t = R_{t+1} + \gamma \hat{q}(S_{t+1}, \mu(S_{t+1}, \theta_t), w_t) - \hat{q}(S_t, A_t, w_t),$$

$$\boxed{\begin{aligned} \theta_{t+1} &= \theta_t + \alpha_\theta \nabla_\theta \mu(S_t, \theta_t) \nabla_a \hat{q}(S_t, a, w_t)\big|_{a=\mu(S_t,\theta_t)}, \\ w_{t+1} &= w_t + \alpha_w \delta_t \nabla_w \hat{q}(S_t, A_t, w_t). \end{aligned}}$$

注意 critic 的当前项使用行为动作 A_t，而 bootstrap 项使用目标动作 $\mu(S_{t+1})$。行为策略必须有探索性；教材举例为在 μ 输出上加入噪声。使用神经网络表示 q 时，这一方向进一步形成 deep deterministic policy gradient（DDPG）的基础。

容易混淆

actor 更新中的动作必须代入 $a = \mu(S_t)$，不是直接在行为动作 A_t 处更新确定性策略；而 critic 当前预测必须评价真实执行的 (S_t, A_t)。把两处动作混成同一个会改变算法。

10.11 四类 Actor–Critic 的统一比较

方法	actor 信号	critic target	数据关系
QAC	$\hat{q}(S, A, w) \nabla \ln \pi$	$R + \gamma \hat{q}(S', A', w)$	on-policy
A2C	$\delta \nabla \ln \pi$	$R + \gamma \hat{v}(S', w)$	on-policy
Off-policy AC	$\rho \delta \nabla \ln \pi$	同上，critic 也乘 ρ	$A \sim \beta$，目标为 π
Deterministic AC	$\nabla_\theta \mu \, \nabla_a \hat{q}$	$R + \gamma \hat{q}(S', \mu(S'), w)$	可 off-policy

识别 Actor–Critic 的固定顺序

先找策略是随机的 π 还是确定性的 μ；再找 actor 使用 q、advantage/TD error，还是动作梯度；最后检查 critic 的 target、行为策略以及是否需要 importance weight。

10.12 初学者最容易产生的九个误解

1. **“Actor–Critic 是与策略梯度无关的第三类方法。”**
   它仍是策略梯度，只是价值由 TD critic 估计。
2. **“critic 决定最终执行哪个动作。”**
   actor 产生动作；critic 提供评价信号。
3. **“减 baseline 会把真梯度缩小。”**
   状态基线不改变期望，主要改变方差。
4. **“$v_\pi(s)$ 总是严格最优 baseline。”**
   教材的精确最优式含 score function 范数权重；v_π 是简洁实用选择。

5. **“TD error 就是真实 advantage。”**
   critic 准确时其条件期望对应 advantage；有限样本和近似 critic 下只是估计。

6. **“off-policy 只需把 actor 乘重要性权重。”**
   教材 Algorithm 10.3 的 critic 更新也乘同一动作权重。

7. **“行为策略可不给目标动作任何概率。”**
   这违反重要性采样覆盖条件。

8. **“确定性策略不需要探索。”**
   目标策略可确定，但收集数据的行为策略仍需探索，例如加入动作噪声。

9. **“DPG 的 actor 和 critic 都在行为动作处求梯度。”**
   critic 当前项用行为动作；actor 的动作梯度在目标动作 $\mu(S)$ 处计算。

10.13 自测题与参考答案

题目

1. REINFORCE 与 QAC 的唯一结构性差别是什么?
2. 证明状态基线 $b(s)$ 不改变策略梯度期望。
3. 写出 A2C 的 δ_t、actor 更新和 critic 更新。
4. 什么时候 $\mathbb{E}[\delta_t \mid s, a] = A_\pi(s, a)$?
5. 写出 off-policy 动作重要性权重及覆盖条件。
6. 写出确定性策略梯度的两个链式因子。
7. 在 deterministic critic target 和 actor 梯度中分别使用哪个动作?

参考答案

1. REINFORCE 用 MC 回报估计 q_π；QAC 用 TD/Sarsa critic 估计 q_π。
2. 对动作求期望后得到 $b(s)\nabla_\theta \sum_a \pi(a \mid s, \theta) = 0$。
3. $\delta_t = R_{t+1} + \gamma \hat{v}(S_{t+1}, w_t) - \hat{v}(S_t, w_t)$；actor 加 $\alpha_\theta \delta_t \nabla \ln \pi$，critic 加 $\alpha_w \delta_t \nabla_w \hat{v}$。
4. 当价值函数等于真实 v_π，并按环境的一步转移对 R, S' 取条件期望时。
5. $\rho_t = \pi(A_t \mid S_t, \theta_t)/\beta(A_t \mid S_t)$；若目标概率非零，行为概率必须非零。
6. $\nabla_\theta \mu(S, \theta)$ 与 $\nabla_a q_\mu(S, a)|_{a=\mu(S)}$。
7. critic target 用 $\mu(S_{t+1})$，actor 动作梯度在 $a = \mu(S_t)$ 处；critic 当前项仍用真实行为动作 A_t。

10.14 一页总结

核心结论

1. Actor–critic 是“策略梯度 actor + TD 价值 critic”，仍属于策略梯度方法。
2. QAC 用 Sarsa critic 估计动作价值；A2C 用状态价值 TD error 估计 advantage。
3. 状态 baseline 不改变策略梯度期望，却可降低随机梯度方差。
4. $A_\pi = q_\pi - v_\pi$ 衡量动作相对当前策略平均水平的好坏。
5. A2C 的同一 δ_t 同时训练 actor 和 critic，但两者参数与梯度不同。
6. Off-policy AC 用 $\rho_t = \pi/\beta$ 修正动作采样，且要求行为策略覆盖目标策略。
7. 教材 Algorithm 10.3 的 actor 和 critic 更新均乘 importance weight。
8. DPG 的 actor 梯度为 $\nabla_\theta \mu \nabla_a q$，自然适合连续动作与 off-policy 数据。
9. 确定性目标策略仍需由探索性行为策略收集有覆盖的数据。

掌握标准：能够从伪代码中独立标出 actor、critic、advantage、behavior/target policy、importance weight 与动作梯度的求值位置。

内容核对说明

本资料逐项核对工作区 `Book` 目录中的：

- `3 - Chapter 10 Actor-Critic Methods.pdf`；
- `Lecture slides/slidesContinuouslyUpdated/L10-Actor Critic.pdf`；
- `Lecture slides/slidesForMyLectureVideos/L10_Actor Critic.pdf`；
- `5 - Errata for the Springer version.pdf`。

专业性处理包括：区分精确最优 baseline 与实用的 v_π baseline；说明 TD error 仅在相应条件下以条件期望表示 advantage；对行为策略写明 importance-sampling 覆盖条件；按教材在 off-policy actor 和 critic 两边使用权重；区分 deterministic critic 的行为动作与 actor 的目标动作求值位置；并采用勘误表修正后的当前参数 θ_t。