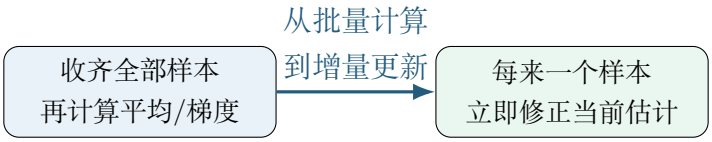
第 6 章：Stochastic Approximation

初学者快速认识与理解指南



核心结论

本章只需要先抓住一个模板：

$$\text{新估计} = \text{旧估计} + \text{学习率} \times \big(\text{新信息} - \text{旧估计所预测的信息}\big).$$

样本均值、Robbins–Monro（RM）算法和随机梯度下降（SGD）都能写成这个形式。L7 的 TD、Sarsa 与 Q-learning 会沿用同一结构。

基于所给 Chapter 6（原书第 101–124 页）与 L6 slides 整理

目标：约 45–60 分钟建立随机逼近知识框架

目录

1 先回答：L6 为什么夹在 MC 与 TD 之间？ 2

1.1 学习本章前应认识的六个词 2

2 数学起点：把样本平均改写成增量更新 2

2.1 与教材下标怎样对应？ 3

2.2 从精确平均到一般随机迭代 3

3 Robbins–Monro：只观察带噪输出也能求根 3

3.1 问题设定 3

3.2 无噪声时为什么方向正确？ 4

3.3 教材给出的收敛条件 4

3.4 均值估计是 RM 的特例 5

4 Dvoretzky 定理：收敛证明的通用工具 5

5 随机梯度下降：用样本梯度替代期望梯度 6

5.1 从总体目标到 SGD 6

5.2 为什么 SGD 是 RM 的特例？ 6

5.3 均值估计又是 SGD 的特例 6

6 BGD、MBGD 与 SGD 放在一起比较 7

7 SGD 的收敛条件与典型收敛形态 7

7.1 为什么离最优点远时常常更快？ 7

8 从 L6 公式直接预告 L7 8

9 初学者最容易产生的七个误解 8

10 建议的快速学习顺序 9

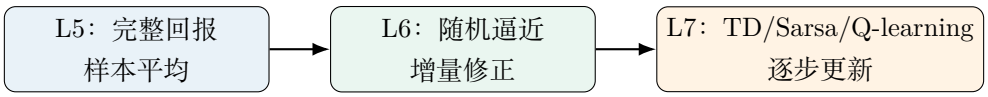
11 自测题与参考答案 9

12 一页总结 10

内容核对说明 10

1 先回答：L6 为什么夹在 MC 与 TD 之间？

L5 的 Monte Carlo（MC）方法先收集完整 episode，再用完整回报的样本平均估计价值。这类表达容易理解，但要等待后续奖励全部出现。L7 的 TD 方法却在每得到一步经验后就立即更新，形式上突然变成随机迭代。L6 的任务正是补上这段知识缺口：



核心结论

本章不引入新的强化学习控制算法。它提供的是后续算法的数学语言：如何只用带噪声的样本，逐次逼近一个期望、方程的根或目标函数的最优点。

1.1 学习本章前应认识的六个词

术语	初学者理解
增量式（incremental）	新样本到达后立刻更新，不必反复保存并处理全部历史样本。
随机逼近（SA）	用带噪声的观测进行随机迭代，求根或求最优解的一大类方法。
学习率/步长	控制一次新信息能把当前估计推多远，常记为 α_k 或 a_k。
带噪观测	真正函数值不可直接获得，只能观测到“真值 + 随机误差”。
几乎必然收敛	除概率为零的异常样本序列外，估计沿样本路径收敛。
随机梯度	用一个随机样本计算的梯度；它是总体期望梯度的带噪估计。

2 数学起点：把样本平均改写成增量更新

设随机变量 X 的期望为 $\mu = \mathbb{E}[X]$，得到 i.i.d. 样本 $x_1, \dots, x_k$。MC 估计为

$$\widehat{\mu}_k = \frac{1}{k}\sum_{i=1}^{k} x_i.$$

直接计算需要对前 k 个样本求和。利用

$$\sum_{i=1}^{k} x_i = (k-1)\widehat{\mu}_{k-1} + x_k,$$

可以得到完全等价的递推式

$$\boxed{\widehat{\mu}_k = \widehat{\mu}_{k-1} - \frac{1}{k}\left(x_k - \widehat{\mu}_{k-1}\right)}, \qquad k \geq 2.$$

直观理解

$x_k - \widehat{\mu}_{k-1}$ 是新样本相对旧估计的“创新”或“预测误差”。若新样本更大，均值向上修正；若新样本更小，均值向下修正。$1/k$ 随样本数减小，意味着后期单个样本不应轻易推翻大量历史证据。

2.1 与教材下标怎样对应？

教材定义

$$w_{k+1} = \frac{1}{k}\sum_{i=1}^{k} x_i, \qquad w_{k+1} = w_k - \frac{1}{k}(w_k - x_k).$$

本文用 $\widehat{\mu}_k$ 表示“处理完 k 个样本后的估计”，只是把下标向前平移了一位，数学内容完全相同。阅读伪代码时，应先确认下标表示“更新前”还是“更新后”，不要仅靠背公式。

四个样本的增量均值

依次观察 $x_1 = 4, x_2 = 8, x_3 = 3, x_4 = 5$。令 $\widehat{\mu}_1 = 4$，则

$$\begin{aligned}\widehat{\mu}_2 &= 4 + \tfrac{1}{2}(8-4) = 6,\\ \widehat{\mu}_3 &= 6 + \tfrac{1}{3}(3-6) = 5,\\ \widehat{\mu}_4 &= 5 + \tfrac{1}{4}(5-5) = 5.\end{aligned}$$

最后结果与批量平均 $(4+8+3+5)/4 = 5$ 完全一致，但更新时只需保存当前均值和计数。

2.2 从精确平均到一般随机迭代

把固定的 $1/k$ 换成一般步长 $\alpha_k > 0$：

$$\boxed{w_{k+1} = w_k + \alpha_k(x_k - w_k) = w_k - \alpha_k(w_k - x_k)}.$$

当 $\alpha_k = 1/k$ 且下标、初始化匹配时，它精确等于样本平均；一般 α_k 下，w_k 不再等于简单算术平均，但在适当条件下仍可收敛到 $\mathbb{E}[X]$。

容易混淆

“增量式”描述的是计算组织方式，不等于“近似得更差”。对 $\alpha_k = 1/k$ 的均值递推，增量式与批量样本平均在精确算术下是同一个数。真正改变统计性质的是步长、样本条件和目标是否变化。

3 Robbins–Monro：只观察带噪输出也能求根

3.1 问题设定

目标是求方程

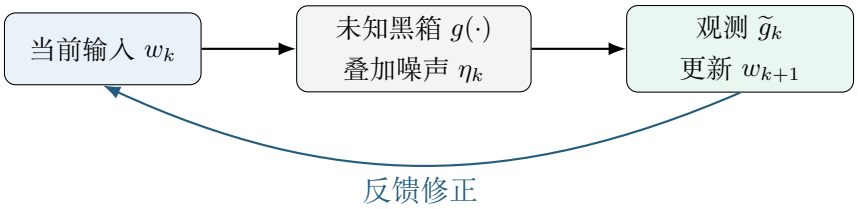
$$g(w) = 0$$

的根 w^*。困难在于不知道 g 的解析式，也不知道它的导数；给定输入 w，只能得到带噪观测

$$\widetilde{g}(w, \eta) = g(w) + \eta.$$

Robbins–Monro 算法为

$$\boxed{w_{k+1} = w_k - a_k \widetilde{g}(w_k, \eta_k)}, \qquad a_k > 0.$$



3.2 无噪声时为什么方向正确？

若 g 单调递增且 $g(w^*) = 0$：

- 当 $w_k > w^*$ 时，$g(w_k) > 0$，所以 $w_{k+1} = w_k - a_k g(w_k) < w_k$；
- 当 $w_k < w^*$ 时，$g(w_k) < 0$，所以 $w_{k+1} > w_k$。

步长足够小时，两侧的迭代都会朝根移动。带噪情况下，单步可能走错方向，但零均值噪声不会长期系统性地把估计推向一侧，而逐渐减小的步长会压低后期波动。

教材 slide 中的线性求根例子

令 $g(w) = w - 10$、$w_1 = 20$、$a_k \equiv 0.5$ 且无噪声，则

$$20 \longrightarrow 15 \longrightarrow 12.5 \longrightarrow 11.25 \longrightarrow \cdots \longrightarrow 10.$$

每一步都把“当前值到根的距离”缩小一半。常步长在这个无噪线性例子中可以收敛；但这不代表常步长自动满足带噪 RM 定理的充分条件。

3.3 教材给出的收敛条件

教材 Theorem 6.1 在标量情形给出一组充分条件。若

$$0 < c_1 \le g'(w) \le c_2, \qquad \forall w,$$

$$\sum_{k=1}^{\infty} a_k = \infty, \qquad \sum_{k=1}^{\infty} a_k^2 < \infty,$$

并且对历史信息 $\mathcal{H}_k$ 有

$$\mathbb{E}[\eta_k \mid \mathcal{H}_k] = 0, \qquad \mathbb{E}[\eta_k^2 \mid \mathcal{H}_k] < \infty,$$

则 w_k 几乎必然收敛到满足 $g(w^*) = 0$ 的根。

条件	它控制什么
$0 < c_1 \le g'(w) \le c_2$	g 严格单调递增，根唯一；斜率还不能无限大。若函数单调递减，可对 $-g$ 应用同样思想。
$\sum a_k = \infty$	总移动能力不能过早耗尽；否则初值很远时可能永远走不到根。
$\sum a_k^2 < \infty$	步长必须趋于零得足够快，使累计噪声影响可控。
条件零均值与有限二阶矩	噪声在给定过去后不能持续偏向一侧，且波动不能无限失控。

为什么两条步长条件要同时满足？

$\sum a_k = \infty$ 要求“别太快停下”，而 $\sum a_k^2 < \infty$ 要求“后期要安静下来”。典型选择 $a_k = 1/k$ 同时满足

$$\sum_{k=1}^{\infty} \frac{1}{k} = \infty, \qquad \sum_{k=1}^{\infty} \frac{1}{k^2} = \frac{\pi^2}{6} < \infty.$$

常步长能不能用？

若 $a_k \equiv a > 0$，则 $\sum a_k^2 = \infty$，不满足上述几乎必然收敛定理。教材同时指出，实践中常使用足够小的常步长，算法仍可在另一种意义下收敛或稳定在真值附近。因此应区分“工程上可用”与“满足本定理、沿样本路径精确收敛”。

3.4 均值估计是 RM 的特例

令

$$g(w) = w - \mathbb{E}[X].$$

虽然 $\mathbb{E}[X]$ 未知，但样本 x_k 给出带噪观测

$$\widetilde{g}(w_k) = w_k - x_k = \underbrace{w_k - \mathbb{E}[X]}_{g(w_k)} + \underbrace{\mathbb{E}[X] - x_k}_{\eta_k}.$$

代入 RM：

$$w_{k+1} = w_k - a_k(w_k - x_k),$$

正好就是一般步长的增量均值算法。这里不要求 X 是高斯分布；教材的关键要求是样本条件、条件零均值噪声与有限波动。

4 Dvoretzky 定理：收敛证明的通用工具

教材 Section 6.3 给出随机过程

$$\Delta_{k+1} = (1 - \alpha_k)\Delta_k + \beta_k \eta_k$$

的收敛定理，并进一步给出可同时处理有限多个分量 $\Delta_k(s)$ 的扩展。其重要性不在于要求初学者立刻背证明，而在于它解释了后续证明的固定套路：

1. 定义估计误差 $\Delta_k =$ 估计 $-$ 真值；
2. 把算法改写成“误差收缩 + 随机扰动”；
3. 验证步长、条件均值和条件方差的界；
4. 推出 $\Delta_k \to 0$ 几乎必然成立。

专业核对

Chapter 6 的 Dvoretzky 扩展能够处理以状态或状态–动作对为索引的多个变量。Chapter 7 正是用这一工具分析表格型 TD；教材还指出，同类扩展可用于 Q-learning 的收敛分析。若当前目标是掌握算法，可先记住证明结构，再回头精读定理细节。

5 随机梯度下降：用样本梯度替代期望梯度

5.1 从总体目标到 SGD

考虑

$$\min_w J(w) = \mathbb{E}[f(w, X)].$$

若能算出真实梯度，普通梯度下降（GD）为

$$w_{k+1} = w_k - \alpha_k \nabla_w J(w_k) = w_k - \alpha_k \mathbb{E}[\nabla_w f(w_k, X)].$$

现实中常不知道 X 的分布，无法直接计算期望梯度。若 x_k 是 X 的样本，SGD 使用

$$\boxed{w_{k+1} = w_k - \alpha_k \nabla_w f(w_k, x_k)}.$$

直观理解

SGD 并不是“随便找一个方向”。在 i.i.d. 采样及适当可积条件下，

$$\mathbb{E}[\nabla_w f(w_k, x_k) \mid w_k] = \mathbb{E}[\nabla_w f(w_k, X)],$$

所以样本梯度对真实梯度是条件无偏的。一次方向可能偏，但平均方向正确。

5.2 为什么 SGD 是 RM 的特例？

优化的一阶条件是

$$g(w) \coloneqq \nabla_w J(w) = \mathbb{E}[\nabla_w f(w, X)] = 0.$$

能观测到的样本梯度可写为

$$\widetilde{g}(w_k) = \nabla_w f(w_k, x_k) = g(w_k) + \underbrace{\nabla_w f(w_k, x_k) - \mathbb{E}[\nabla_w f(w_k, X)]}_{\eta_k}.$$

因此 RM 更新 $w_{k+1} = w_k - \alpha_k \widetilde{g}(w_k)$ 就是 SGD。

5.3 均值估计又是 SGD 的特例

把求均值写成优化问题：

$$\min_w J(w) = \mathbb{E}\left[\frac{1}{2}\|w - X\|^2\right].$$

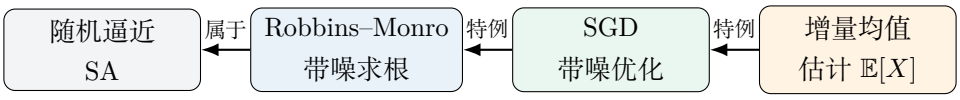
因为

$$\nabla_w f(w, X) = w - X,$$

SGD 变成

$$w_{k+1} = w_k - \alpha_k (w_k - x_k),$$

恰好是前面的均值递推。



6 BGD、MBGD 与 SGD 放在一起比较

给定样本 $\{x_i\}_{i=1}^n$，三类更新可统一写为：

$$\begin{aligned}
\text{BGD:}\quad & w_{k+1} = w_k - \alpha_k \frac{1}{n}\sum_{i=1}^{n} \nabla f(w_k, x_i), \\
\text{MBGD:}\quad & w_{k+1} = w_k - \alpha_k \frac{1}{m}\sum_{j\in I_k} \nabla f(w_k, x_j), \quad |I_k| = m, \\
\text{SGD:}\quad & w_{k+1} = w_k - \alpha_k \nabla f(w_k, x_k).
\end{aligned}$$

方法	每步样本数	优点	代价/波动
BGD	全部 n 个	在固定数据集上每步方向最稳定	数据量大时每步计算昂贵
MBGD	m 个	在吞吐量与随机性之间折中	仍需选择批大小与采样方式
SGD	1 个	单步便宜、样本一到即可更新	梯度方差最大，后期可能波动

为什么 $m = n$ 的 MBGD 未必就是 BGD？

教材的 MBGD 令批中样本由独立随机抽取产生，可能重复抽到同一个样本，也可能漏掉另一个样本。因此即使抽取 n 次，也未必恰好覆盖数据集中的每个元素一次。只有明确使用“全体样本各一次”的批，才与 BGD 相同。

7 SGD 的收敛条件与典型收敛形态

教材 Theorem 6.4 在标量情形给出一组充分条件：

$$0 < c_1 \le \nabla_w^2 f(w, X) \le c_2, \qquad \sum_k \alpha_k = \infty, \qquad \sum_k \alpha_k^2 < \infty,$$

且 $\{x_k\}$ 为 i.i.d. 样本。在这些条件下，w_k 几乎必然收敛到 $\nabla_w \mathbb{E}[f(w, X)] = 0$ 的根。向量情形中，标量二阶导数对应 Hessian，需要用正定性与谱界表达相应条件。

7.1 为什么离最优点远时常常更快？

教材用随机梯度相对误差

$$\delta_k = \frac{|\nabla f(w_k, x_k) - \mathbb{E}[\nabla f(w_k, X)]|}{|\mathbb{E}[\nabla f(w_k, X)]|}$$

分析这一现象。在强凸条件下，可得到形如

$$\delta_k \le \frac{|\nabla f(w_k, x_k) - \mathbb{E}[\nabla f(w_k, X)]|}{c|w_k - w^*|}.$$

当 w_k 离 w^* 较远时，真实梯度信号较强，随机误差相对较小；接近最优点时真实梯度趋近于零，同样大小的采样噪声会显得更突出，于是轨迹更容易抖动。

容易混淆

上式给出的是相对误差的上界和典型解释，不是“SGD 每一步都比上一步更靠近最优点”的保证。随机算法允许短期回退；收敛定理描述的是长期样本路径性质。

8 从 L6 公式直接预告 L7

L6 最值得带到下一章的不是某个具体证明，而是同一个修正模板：

$$\theta_{k+1} = \theta_k - \alpha_k \underbrace{\left(\text{当前估计} - \text{随机目标}\right)}_{\text{带噪残差}}.$$

L7 的状态价值 TD 会写成

$$v_{t+1}(s_t) = v_t(s_t) - \alpha_t \left[v_t(s_t) - \left(r_{t+1} + \gamma v_t(s_{t+1})\right)\right].$$

对照即可看出：$r_{t+1} + \gamma v_t(s_{t+1})$ 是随机目标，整个算法是用一步经验修正 Bellman 方程的残差。

核心结论

均值估计使用样本 x_k 作为目标；SGD 使用样本梯度作为方向；TD 使用“一步奖励 + 下一状态当前价值”作为目标。对象不同，但“旧估计 + 步长 × 新信息”的骨架相同。

9 初学者最容易产生的七个误解

1. **“随机逼近就是 SGD。”**
   不准确。随机逼近是一大类方法；SGD 是 RM 的特殊形式，RM 又属于随机逼近。

2. **“有噪声就必须假设高斯分布。”**
   不需要。教材 RM 定理关心条件零均值和有限二阶矩，并不要求噪声为高斯。

3. **“$\sum a_k^2 < \infty$ 单独就够了。”**
   不够。还要 $\sum a_k = \infty$，否则总移动距离可能有限，初值很远时到不了根。

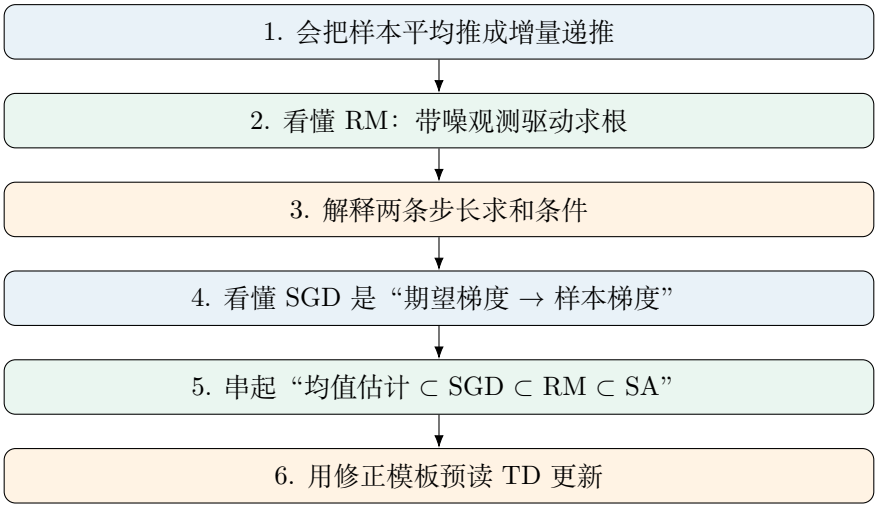
4. **“常步长不满足定理，所以实践中不能用。”**
   错误。它不满足该几乎必然精确收敛定理，但可用于跟踪变化目标，或稳定在真值附近。

5. **“样本梯度等于真实梯度。”**
   单个样本一般不相等；在适当采样条件下，它的条件期望等于真实梯度。

6. **“增量均值一定只是近似批量均值。”**
   当步长为对应的 $1/k$ 且初始化、下标一致时，两者代数上完全相同。

7. **“收敛意味着有限步后精确等于真值。”**
   收敛是 $k \to \infty$ 的性质。有限样本下仍会有估计误差。

10 建议的快速学习顺序



11 自测题与参考答案

题目

1. 样本为 $2, 6, 7$。用增量公式计算处理完三个样本后的均值。
2. 为什么 RM 的噪声条件写成 $\mathbb{E}[\eta_k \mid \mathcal{H}_k] = 0$，而不只写 $\mathbb{E}[\eta_k] = 0$?
3. 判断 $a_k = 1/k$ 与常数 $a_k = 0.01$ 是否满足两条 RM 步长求和条件。
4. 写出把均值估计表示为 SGD 时使用的单样本损失。
5. BGD、MBGD、SGD 每步分别使用多少样本?
6. 为什么接近最优点时 SGD 的轨迹常显得更随机?

参考答案

1. $\widehat{\mu}_1 = 2$，$\widehat{\mu}_2 = 2 + \frac{1}{2}(6 - 2) = 4$，$\widehat{\mu}_3 = 4 + \frac{1}{3}(7 - 4) = 5$。
2. 因为当前噪声可能依赖过去；条件零均值排除了“给定已知历史后仍有系统偏差”的情况，正是随机迭代证明所需的更强、也更合适的条件。
3. $1/k$ 满足 $\sum a_k = \infty$、$\sum a_k^2 < \infty$；常数 0.01 的平方和发散，因此不满足。
4. $f(w, x) = \frac{1}{2}\|w - x\|^2$。
5. BGD 用全部样本；MBGD 用 m 个样本；SGD 用一个样本。
6. 接近最优点时真实梯度趋近于零，采样误差相对于真实梯度更显著。

12 一页总结

核心结论

1. 样本均值可精确改写为增量式：$\widehat{\mu}_k = \widehat{\mu}_{k-1} + \frac{1}{k}(x_k - \widehat{\mu}_{k-1})$。
2. RM 用 $w_{k+1} = w_k - a_k \widetilde{g}(w_k, \eta_k)$ 从带噪输出求 $g(w) = 0$。
3. 两条经典步长条件分别保证“还能继续走”和“噪声最终被压低”。
4. 均值估计是 RM 的特例；SGD 也是 RM 的特例。
5. SGD 用单样本梯度替代期望梯度；单步有噪声，但在适当条件下平均方向正确。
6. BGD、MBGD、SGD 的核心差别是每步使用的样本数量及由此产生的计算量与方差。
7. Dvoretzky 定理把算法误差写成“收缩项 + 扰动项”，是后续 TD/Q-learning 收敛分析的工具。
8. L7 会把随机目标换成 TD target，继续使用同一个增量修正模板。

掌握标准：看到一个随机迭代式时，能够指出当前估计、步长、带噪观测/随机目标，并说明它在逼近哪个期望、方程根或最优点。

内容核对说明

本资料的定义、公式、定理条件与章节结构以工作区内的 Book 目录为依据：

`Book-Mathematical-Foundation-of-Reinforcement-Learning-main`

具体核对文件如下：

- `3 - Chapter 6 Stochastic Approximation.pdf`（原书第 101–124 页）；
- `Lecture slides/slidesContinuouslyUpdated/L6-Stochastic approximation.pdf`；
- `Lecture slides/slidesForMyLectureVideos/L6-Stochastic approximation and stochastic gradient descent.pdf`；
- `5 - Errata for the Springer version.pdf`（该勘误表未列出 Chapter 6 修正，且注明 GitHub PDF 已吸收已知勘误）。

为降低下标歧义，本文在均值递推处采用“处理完 k 个样本后记为 $\widehat{\mu}_k$”的记号，并明确给出与教材 w_{k+1} 记号的对应关系。Dvoretzky 定理的完整证明未复刻，但其用途与误差递推结构按教材保留。