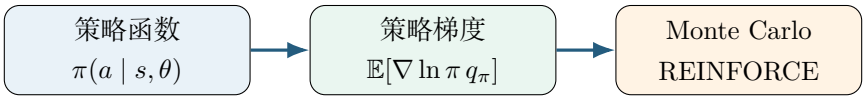
第 9 章：Policy Gradient Methods

初学者快速认识与理解指南



核心结论

L9 第一次不再“先学价值再取贪心动作”，而是直接调整策略概率：

$$\theta \leftarrow \theta + alpha \nabla_\theta \ln \pi(A \mid S, \theta) \times \text{动作价值样本}.$$

REINFORCE 用完整回报作为动作价值样本；L10 将改用 TD critic。

基于 Book Chapter 9（原书第 190–214 页）与 L9 连续更新 slides 整理

覆盖：策略参数化、平均价值/奖励、策略梯度定理与 REINFORCE

目录

9 L9：Policy Gradient Methods——直接优化策略 2
9.1 从策略表到策略函数 . . . 2
9.2 指标一：平均状态价值 . . . 2
9.3 指标二：平均一步奖励 . . . 3
9.4 策略梯度定理：最重要的统一表达 . . . 3
9.5 为什么梯度里会出现对数 . . . 3
9.6 梯度方向的直观解释 . . . 4
9.7 REINFORCE：用 Monte Carlo 回报估计动作价值 . . . 4
9.8 REINFORCE 的采样条件、优点与局限 . . . 4
9.9 初学者最容易产生的七个误解 . . . 5
9.10 自测题与参考答案 . . . 5
9.11 一页总结 . . . 6

内容核对说明 6

9 L9：Policy Gradient Methods——直接优化策略

L1–L8 的主角一直是价值函数：先估计 v 或 q，再从价值中提取策略。L9 第一次把策略本身写成可微函数 $\pi(a \mid s, \theta)$，选择一个标量指标 $J(\theta)$，然后直接做梯度上升：

$$\theta_{t+1} = \theta_t + \alpha_t \nabla_\theta J(\theta_t).$$

L9 的三问

1. 用哪个标量指标定义“策略更好”？
2. 指标的梯度怎样写成可采样的期望？
3. 未知的 q_π 怎样用 Monte Carlo 样本替代？

答案依次是：平均价值/平均奖励、策略梯度定理、REINFORCE。

9.1 从策略表到策略函数

表格策略为每个 (s, a) 保存一个概率；函数策略用共享参数生成整个动作分布：

$$\pi(a \mid s, \theta), \qquad \sum_{a \in \mathcal{A}} \pi(a \mid s, \theta) = 1.$$

离散动作下，教材使用 softmax 参数化：

$$\boxed{\pi(a \mid s, \theta) = \frac{\exp(h(s, a, \theta))}{\sum_{a'} \exp(h(s, a', \theta))}}.$$

h 是动作偏好，可由线性函数或神经网络产生。softmax 保证每个动作概率为正且总和为一，因此 $\ln \pi(a \mid s, \theta)$ 有定义，策略也具有随机探索性。

直观理解

价值方法先问“每个动作值多少”，再选最大者；策略方法直接问“动作概率应怎样改变”。共享参数让相似状态的策略相互泛化，代价是优化目标通常非凸，不能仅凭梯度上升保证找到全局最优策略。

9.2 指标一：平均状态价值

给定状态权重分布 d，定义

$$\bar{v}_\pi = \sum_s d(s) v_\pi(s) = \mathbb{E}_{S \sim d}[v_\pi(S)].$$

教材区分两类 d：

- d_0 与策略无关，例如均匀分布，或只关心固定初始状态 s_0；此时记作 $\bar{v}_\pi^0$；
- d_π 是策略诱导的平稳分布，按长期访问频率给状态加权；此时常简记 $\bar{v}_\pi$。

在折扣任务中，从 $S_0 \sim d$ 出发的期望折扣回报满足

$$J(\theta) = \mathbb{E}_\pi\left[\sum_{t=0}^{\infty} \gamma^t R_{t+1}\right] = \sum_s d(s) v_\pi(s).$$

9.3 指标二：平均一步奖励

令

$$r_\pi(s) = \sum_a \pi(a \mid s, \theta) r(s, a),$$

平均奖励定义为

$$\bar{r}_\pi = \sum_s d_\pi(s) r_\pi(s) = \mathbb{E}_{S \sim d_\pi}[r_\pi(S)].$$

它也等于长期时间平均奖励：

$$\bar{r}_\pi = \lim_{n \to \infty} \frac{1}{n} \mathbb{E}_\pi \left[\sum_{t=0}^{n-1} R_{t+1} \right],$$

这里需要教材关于平稳分布和长期极限的适当条件。

在折扣情形且平均价值按 d_π 加权时，教材给出

$$\bar{r}_\pi = (1 - \gamma) \bar{v}_\pi,$$

所以二者可被同时最大化。

三个指标不能只看名字混写

$\bar{v}_\pi^0$、$\bar{v}_\pi$ 与 $\bar{r}_\pi$ 的状态权重不同。策略梯度中的状态分布也会随指标与折扣/不折扣设定变化；不能把一个推导中的分布直接搬到所有场景。

9.4 策略梯度定理：最重要的统一表达

教材 Theorem 9.1 将多种指标下的结果统一写成

$$\boxed{\nabla_\theta J(\theta) = \sum_s \eta(s) \sum_a \nabla_\theta \pi(a \mid s, \theta) q_\pi(s, a)},$$

也可写成期望形式

$$\boxed{\nabla_\theta J(\theta) = \mathbb{E}_{S \sim \eta, A \sim \pi} \left[\nabla_\theta \ln \pi(A \mid S, \theta) q_\pi(S, A) \right]}.$$

这里 η 是与具体指标相匹配的状态分布。

统一定理的专业读法

Theorem 9.1 是教材对多个定理的汇总。J 可以是 $\bar{v}_\pi^0$、$\bar{v}_\pi$ 或 $\bar{r}_\pi$；η 随场景变化，某些表达是严格等式，某些是教材说明的近似。因此应记住梯度的**结构**，但不能省略具体问题的指标与采样分布。

9.5 为什么梯度里会出现对数

关键恒等式是 log-derivative trick：

$$\nabla_\theta \ln \pi(a \mid s, \theta) = \frac{\nabla_\theta \pi(a \mid s, \theta)}{\pi(a \mid s, \theta)},$$

从而

$$\nabla_\theta \pi(a \mid s, \theta) = \pi(a \mid s, \theta) \nabla_\theta \ln \pi(a \mid s, \theta).$$

原来对所有动作求和的梯度因此变成 $A \sim \pi$ 下的期望，才可以用一次动作样本构造随机梯度。

softmax 的 score function

若某状态的偏好参数为 $h_1, \dots, h_K$，则对实际选择的动作 a，

$$\frac{\partial \ln \pi(a \mid s)}{\partial h_j} = \mathbf{1}\{j = a\} - \pi(j \mid s).$$

因此提高动作 a 的偏好时，归一化会同时压低其他动作的相对概率。

9.6 梯度方向的直观解释

用单样本近似真梯度可写成

$$\theta_{t+1} = \theta_t + \alpha_t \nabla_\theta \ln \pi(A_t \mid S_t, \theta_t) q_t(S_t, A_t).$$

又因为

$$\nabla_\theta \ln \pi = \frac{\nabla_\theta \pi}{\pi},$$

它可看作沿 $\pi(A_t \mid S_t, \theta)$ 的上升方向调整：估计价值为正时增强所选动作，估计价值为负时削弱所选动作。L10 会通过减去 baseline，把“绝对价值”改成“相对平均水平的优势”，从而降低方差并使解释更自然。

9.7 REINFORCE：用 Monte Carlo 回报估计动作价值

真实 $q_\pi(S_t, A_t)$ 未知。对 episodic task，使用从 t 开始的完整回报

$$G_t = \sum_{k=t+1}^{T} \gamma^{k-t-1} R_k$$

作为样本，得到教材 Algorithm 9.1：

$$\boxed{\theta \leftarrow \theta + alpha G_t \nabla_\theta \ln \pi(A_t \mid S_t, \theta)}.$$

REINFORCE：每个 episode

1. 按当前 $\pi(\cdot \mid \cdot, \theta)$ 生成完整轨迹；
2. 对每个 t 从后向前计算回报 G_t；
3. 用 $G_t \nabla_\theta \ln \pi(A_t \mid S_t, \theta)$ 做梯度上升；
4. 新策略继续生成下一批 on-policy 轨迹。

它被称为 Monte Carlo policy gradient，因为直到 episode 结束才能获得完整 G_t，且不使用 bootstrap。

9.8 REINFORCE 的采样条件、优点与局限

策略梯度期望要求 $S \sim \eta$、$A \sim \pi(\cdot \mid S, \theta)$。教材的实用实现按当前策略生成 episode，再复用其中每个时间步；因此它是 on-policy，同时比严格独立地重新采每个状态–动作样本更节省经验。

维度	REINFORCE	L8 的 TD/Q 方法
直接更新	策略参数 θ	价值参数 w
价值样本	完整回报 G_t	一步或多步 bootstrap target
方差/偏差	通常方差较高；不由当前价值函数 bootstrap	通常方差较低，但依赖当前价值估计
更新时机	通常等 episode 结束	可逐时间步更新

容易混淆

“直接优化策略”不等于“不需要价值信息”。策略梯度定理仍用 $q_\pi(S, A)$ 给动作的概率更新加权；REINFORCE 只是用 Monte Carlo 回报估计这个价值。L10 的 actor–critic 会改用 TD critic 估计它。

9.9 初学者最容易产生的七个误解

1. **“策略梯度就是对奖励 R_t 直接求导。”**
   环境奖励与转移通常不可直接对 θ 求导；定理通过 log-policy 与 q_π 表达梯度。
2. **“η 永远等于平稳分布 d_π。”**
   不对。它由指标和折扣设定决定，也可能是折扣总访问分布。
3. **“$\ln \pi$ 是新目标函数。”**
   不是。它是把概率梯度改写为可采样期望的工具。
4. **“REINFORCE 不估计价值。”**
   它用 G_t 对 $q_\pi(S_t, A_t)$ 做 MC 估计。
5. **“softmax 输出最大的动作就是本次动作。”**
   随机策略应按输出概率采样，而不是每次都取最大者。
6. **“梯度上升一定找到全局最优策略。”**
   参数化目标通常非凸，梯度方法一般只提供局部/驻点意义的优化过程。
7. **“一条旧策略轨迹可以无修正地训练任意新策略。”**
   基础 REINFORCE 是 on-policy；使用其他行为策略的数据需要 L10 的分布修正思想。

9.10 自测题与参考答案

题目

1. 写出平均状态价值与平均奖励，并指出各自使用的状态分布。
2. 为什么 $\nabla_\theta \ln \pi$ 能把动作求和变成采样期望?
3. 写出策略梯度定理的期望形式，并说明 η 为什么不能省略。
4. 写出 REINFORCE 更新，并说明它为何属于 Monte Carlo 和 on-policy。

5. 若 $G_t < 0$，一次 REINFORCE 更新倾向于怎样改变已选动作概率?

参考答案

1. $\bar{v}_\pi = \sum_s d(s) v_\pi(s)$；$\bar{r}_\pi = \sum_s d_\pi(s) r_\pi(s)$。
2. 因为 $\nabla \pi = \pi \nabla \ln \pi$，求和中的 π 正好成为采样概率。
3. $\mathbb{E}_{S\sim\eta, A\sim\pi}[\nabla \ln \pi(A \mid S, \theta) q_\pi(S, A)]$；$\eta$ 与所优化指标及折扣情形绑定。
4. $\theta \leftarrow \theta + \alpha G_t \nabla \ln \pi(A_t \mid S_t, \theta)$；$G_t$ 是完整回报，轨迹由当前待优化策略生成。
5. 在足够小的更新下，倾向于降低该状态下已选动作的概率。

9.11 一页总结

核心结论

1. L9 从价值函数参数 w 转向策略参数 θ，用梯度上升直接改善策略。
2. 常用指标是平均状态价值和平均奖励；指标决定正确的状态加权分布。
3. 策略梯度的统一结构是 $\mathbb{E}[\nabla_\theta \ln \pi(A \mid S, \theta) q_\pi(S, A)]$。
4. 对数导数技巧把动作求和改写为可用单个动作样本估计的期望。
5. softmax 保证离散动作概率为正且和为一；动作应按概率采样。
6. REINFORCE 用完整回报 G_t 估计 q_π，是 on-policy Monte Carlo 策略梯度。
7. REINFORCE 不 bootstrap，概念简单但通常方差较高；L10 将用 baseline 和 TD critic 改进。

掌握标准：看到策略梯度公式时，能指出目标指标、状态分布、行为策略、score function 和价值估计来源。

内容核对说明

本资料逐项核对工作区 `Book` 目录中的：

- `3 - Chapter 9 Policy Gradient Methods.pdf`；
- `Lecture slides/slidesContinuouslyUpdated/L9-Policy gradient methods.pdf`；
- `Lecture slides/slidesForMyLectureVideos/L9_Policy gradient.pdf`；
- `5 - Errata for the Springer version.pdf`。

专业性处理包括：区分 $\bar{v}_\pi^0$、$\bar{v}_\pi$ 与 $\bar{r}_\pi$；明确统一策略梯度定理中的 η 依具体指标而变；限制 log-policy 对正概率策略的要求；将 REINFORCE 明确为使用完整回报的 on-policy Monte Carlo 策

略梯度；并按勘误表采用 Chapter 9 中正确的矩阵极限次序 $P_\pi^k \to \mathbf{1} d_\pi^\top$。